SUBTITIS

Titlovi iz zvuka, i prevod gotovih titlova

Lokalna aplikacija za transkripciju, prelamanje i prevod. Nijedan zapis ne napušta mašinu.

> „Dobar titl se ne primećuje. Loš titl je jedino što gledalac vidi.“
>
> pravilo struke

Projektni dokument · v1.4
Beograd, oktobar 2026.

Izradio Mirko Rudić
uz pomoć Claude Opus 5 (Anthropic)

Sadržaj

1. Uvod i povod 3

2. Vizija i principi proizvoda 4

3. Šta je potrebno da bi alat radio 5

4. Model podataka i pojmovnik 6

5. Obrada — pajplajn 8

    5.1. Prepoznavanje govora 8

    5.2. Jezičke normalizacije 10

    5.3. Restauracija interpunkcije 11

    5.4. Segmentacija 12

    5.5. Prelamanje u cue-ove 13

    5.6. Transliteracija i izlazne transformacije 16

6. Prevod 17

7. Prevod postojećeg SRT-a 20

8. Ekrani aplikacije 23

    8.1. Četiri pravila interfejsa 23

    8.2. Početni ekran 23

    8.3. Stranica projekta 24

    8.4. Editor i prelom ispod rečenice 25

    8.5. Podešavanja 26

    8.6. Objašnjenja u interfejsu 26

9. Funkcionalna pravila 28

10. Izlaz, disk i rezervne kopije 30

11. Tehnička osnova 31

12. Izmereni rezultati 33

13. Faze razvoja 37

14. Rizici i otvorena pitanja za javnu verziju 39

Prilog A — prompt za izgradnju alata 41

1. Uvod i povod

Subtitis je lokalna aplikacija koja od audio ili video zapisa pravi gotov SRT titl i, po potrebi, prevodi ga. Dokument je za onoga ko treba da razume šta je izgrađeno i zašto: vlasnika proizvoda, tim koji preuzima razvoj, ili nekoga ko procenjuje isplati li se proširiti u javni proizvod.

Povod nije pretpostavka o tržištu nego ponovljiv posao. Autor redovno obrađuje video priloge do tri minuta, koji traže titl na jeziku originala i često prevod na engleski ili francuski. Automatski servisi daju transkript koji jeste tačan, ali kao titl ne valja: cue-ovi traju dvanaest sekundi, seku se nasred rečenice, imaju devedeset znakova u redu i lome se između predloga i imenice. Čoveku ne ostaje korektura nego prekrajanje celog fajla.

Druga polovina problema je srpski. Modeli za prepoznavanje govora tretiraju srpski i hrvatski kao jedan jezik, pa detekcija redovno vraća hrvatski, a s njim i ijekavske oblike koji se posle ispravljaju kroz ceo fajl. Pisma se mešaju unutar istog zapisa. Komercijalni prevodioci daju tečan ali generički tekst, bez terminologije organizacija čije priloge autor obrađuje.

Subtitis razdvaja ono što su drugi alati spojili: **prepoznavanje govora i pravljenje titla su dva posla.** Model vraća pojedinačne reči sa vremenima, a titl se iz njih gradi po pravilima struke — dužina reda, brzina čitanja, sintaksičke granice preloma. Pravila su izražena kao merljivi kazneni poeni, ne kao heuristike, pa se menjaju bez ponovne obrade.

Sve radi na autorovom računaru. Nijedan zapis ne napušta mašinu, nema pretplate ni ograničenja minuta. To je bio uslov, ne posledica: materijal često sadrži izjave dece i korisnika socijalnih usluga, i slanje takvog zvuka trećoj strani nije dolazilo u obzir.

> **Ceo postupak izgradnje stoji u Prilogu A.** Jedan tekst koji se nalepi u agenta za pisanje koda u praznom folderu; iz njega nastaje sve opisano ovde, sa dvadeset šest zamki pronađenih merenjem — one se bez tog spiska plaćaju ponovo.

> **Šta ovo nije.** Nije tehnička specifikacija — sistem je izgrađen i radi. Ovde stoje odluke, izmerene vrednosti i razlozi, tako da budu jasni i nekome ko nije učestvovao u razvoju. Sve brojke su izmerene na stvarnom materijalu, ne procenjene.

2. Vizija i principi proizvoda

Subtitis je alat za jednog čoveka koji zna šta radi. Ne zamenjuje prevodioca i ne automatizuje prosuđivanje: uklanja mehanički deo posla i ostavlja čoveku odluku šta je rečeno i kako to stoji na ekranu.

Šest principa

1. Jedan izvor istine, sve ostalo izvedeno. Datoteka sa rečima i vremenima je jedini nezamenljiv artefakt; titlovi, prevodi i prelomi izvedeni su iz nje i regenerišu se u sekundi. Otuda: promena profila ne pokreće prepoznavanje, a nov ciljni jezik ne pokreće ni prepoznavanje ni ponovni prevod originala.

2. Tiha greška je gora od pada. Prazan rezultat sa oznakom „gotovo" šteti više od poruke o grešci. Svaka faza prijavljuje šta je zatekla i šta je uradila; prazan prepis je greška, ne uspeh; svako odbacivanje odgovora modela beleži se sa razlogom.

3. Merenje pobeđuje pretpostavku. Hipoteza o uzroku kvara više puta je bila pogrešna, a merenje je pokazalo drugo. Zato su svi pragovi imenovane konstante sa zabeleženim razlogom, a alat ispisuje veličine na osnovu kojih je odlučio — da se prag proveri, a ne pogađa.

4. Mašina ne prepravlja ono što je čovek rekao. Modeli koji dodaju interpunkciju ili prevode vole da usput „poprave" formulaciju. Svaki odgovor prolazi proveru da je niz reči ostao isti: pravopisne ispravke su dozvoljene i beleže se, izmene sadržaja se odbacuju.

5. Ručna ispravka je svetinja. Kad čovek ispravi tekst, nijedna automatska faza ga ne pregazi. Datoteka nosi oznaku da je menjana ljudskom rukom, ponovno pokretanje traži potvrdu, a pre svake izmene pravi se rezervna kopija.

6. Ništa ne napušta računar. Prepoznavanje, prevod i obrada rade lokalno. Nema naloga, oblaka ni telemetrije.

Šta alat namerno ne radi

- **Ne prepoznaje govornike.** Materijal su monolozi i kratke izjave; razdvajanje bi tražilo još jedan model u memoriji kartice bez srazmerne koristi.
- **Ne uređuje video.** Ulaz može biti video, izlaz je uvek zaseban SRT — ugrađivanje titla u sliku je posao montaže.
- **Ne pogađa šta korisnik hoće.** Prevod se ne pokreće sam posle prepoznavanja: pauza za pregled postoji zato što prevod neispravljenog teksta prevodi i greške.
- **Ne skriva svoje odluke.** Stranica projekta pokazuje kojim je modelom rađeno, koliko je trajalo i gde su napravljeni ustupci.

3. Šta je potrebno da bi alat radio

Sve se izvršava na jednoj mašini, pa je hardverski zahtev stvaran i ne može se zaobići bez promene prirode proizvoda (poglavlje 14).

Deo	Zahtev	Zašto
Grafička kartica	NVIDIA, najmanje 12 GB memorije	model za prepoznavanje ~5 GB, model za prevod ~8 GB; nikad istovremeno, ali svaki mora da stane
Prostor na disku	~15 GB za modele, plus 115 MB po satu zapisa	radna kopija zvuka se briše sama posle zadatog roka
Procesor i radna memorija	bilo šta savremeno	ceo posao radi kartica
Operativni sistem	Windows 10 ili noviji	razvijano i mereno na njemu; na Linuxu radi isto, osim zaobilaženja opisanih za Windows

Program	Verzija	Napomena
Python	3.11	**ne 3.12** — biblioteka za rad sa karticom na njoj ume da ne proradi
ffmpeg	bilo koja skorašnja	mora biti dostupan iz komandne linije; alat ga traži i po poznatim mestima instalacije, jer razvojna okruženja drže zastarelu kopiju putanja
Ollama	bilo koja skorašnja	radi lokalno; model za prevod se preuzima jednom, oko 8 GB
model za prepoznavanje	`large-v3`	preuzima se sam pri prvom pokretanju, oko 5 GB

Nema Dockera, koraka izgradnje ni paketa za pregledač. Sve što stranica koristi stoji u projektu, fontovi uključeni — inače bi svako otvaranje ekrana slalo zahtev van računara.

Postavljanje od nule

1. Python 3.11, uz „Add to PATH“.
2. `ffmpeg`, tako da se poziva iz komandne linije.
3. NVIDIA drajver. CUDA Toolkit nije potreban, dolazi uz drajver.
4. Ollama, pa `ollama pull gemma3:12b`.
5. Projekat: `python -m venv .venv`, aktivacija, `pip install -r requirements.txt`.
6. `subtitis doctor` — ispisuje šta nedostaje i komandu za svaku stavku.
7. `subtitis serve`, ili prečica na radnoj površini.

Model za prepoznavanje preuzima se sam pri prvom poslu, pa prvi prepis traje nekoliko minuta duže. `doctor` je jedini opis postavljanja koji ne zastareva, jer se izvršava.

4. Model podataka i pojmovnik

Sve počiva na razlici između tri nivoa: **reč**, **rečenica** i **cue**. Alati za titlovanje ih redovno mešaju, i odatle dolazi većina loših titlova.

Pojam	Šta jeste	Odakle dolazi
Reč	jedan token sa početkom, krajem i verovatnoćom	model za prepoznavanje govora
Rečenica	smislena celina, granica po interpunkciji ili pauzi	segmentacija nad rečima
Cue	jedan titl na ekranu — jedan ili dva reda, sa svojim trajanjem	prelamanje rečenice po profilu
Profil	skup pravila: znakova po redu, brzina čitanja, min/max trajanje	datoteka u `profiles/`
Posao	jedan obrađeni zapis sa svim izvedenim datotekama	direktorijum u `jobs/`
Glosar	tabela termina koji se ne smeju prevoditi proizvoljno	datoteka u `glossary/`

Izvor istine — datoteka reči

Svaki posao ima jednu datoteku sa svim rečima i vremenima. Ona se jedina ne može regenerisati; sve ostalo je iz nje izvedeno.

```
{
  "schema_version": 1,
  "job_id": "20260812-091232-test3",
  "source_file": "test3.wav",
  "duration": 180.44,
  "language": "fr",
  "script": "Latn",
  "asr": {
    "model": "faster-whisper/large-v3",
    "params": { "vad_filter": true, "condition_on_previous_text": false, ... },
    "detected_language": "fr",
    "detected_probability": 1.00
  },
  "words": [
    { "i": 0, "s": 0.00, "e": 0.34, "w": "Je",       "p": 0.99 },
    { "i": 1, "s": 0.34, "e": 0.61, "w": "m'arrête", "p": 0.97 },
    { "i": 2, "s": 0.61, "e": 1.02, "w": "ici",      "p": 0.58 }
  ]
}
```

Imena polja su kratka namerno. Sat govora nosi oko devet hiljada reči; puna imena bi datoteku utrostručila bez koristi, jer je čovek ne čita direktno.

Polje `i` je stabilan indeks, ne pozicija u nizu: kad ručna ispravka izbriše reč, sve reference i dalje važe. Polje `p` je verovatnoća i najkorisniji podatak u datoteci — u editoru se reči sa niskom verovatnoćom boje, pa se korektura svodi na obojena mesta umesto na čitanje celog teksta.

Interpunkcijski znaci su zasebne stavke sa svojim vremenom. Deluje neobično, ali prelom se dešava posle zareza i mora se znati u kojoj milisekundi.

`script` je odvojen od `language`: `sr` + `Latn` i `sr` + `Cyrl` su isti jezik u dva pisma, dve izvedene verzije istog sadržaja.

Rečenice

Nastaje posle segmentacije, po jedan za svaki jezik.

```
{
  "schema_version": 1,
  "language": "fr",
  "script": "Latn",
  "derived_from": "words.fr.json",
  "edited_by_human": false,
  "sentences": [
    {
      "id": 1,
      "s": 0.00, "e": 3.06,
      "text": "Je m'arrête ici, il fait nuit.",
      "words": [0, 7],
      "speaker": null,
      "flags": ["low_confidence"]
    }
  ]
}
```

`words` je uključiv raspon indeksa. Preko njega se iz rečenice stiže do tačnih vremena pojedinačnih reči, pa cue dobija prava vremena, a ne interpolirana.

`edited_by_human` je važnije nego što izgleda: dok stoji, nijedna automatska faza ne prepisuje datoteku. Bez toga jedan klik na „pokreni ponovo" briše pola sata korekture — greška koja se napravi jednom i pamti dugo.

Prevod je datoteka istog oblika, sa **istim vrednostima** `id` i preuzetim vremenima — zato se original i prevod mogu prikazati jedan pored drugog, red do reda.

Struktura posla na disku

```
jobs/<job_id>/
  job.json              status, parametri, istorija faza
  source.wav            16 kHz mono — radna kopija, briše se posle 7 dana
  words.fr.json         IZVOR ISTINE
  sentences.fr.json     original, uređuje se u editoru
  sentences.sr.json     prevod
  out/test3.fr.srt
  out/test3.sr-Cyrl.srt
  log.txt               sve faze, trajanja, odbačeni odgovori
```

Titlovi se imenuju po standardu oznaka jezika, sa pismom gde treba: `ime.fr.srt`, `ime.sr-Latn.srt`, `ime.sr-Cyrl.srt`.

5. Obrada — pajplajn

Put od zapisa do titla ima osam koraka. Svaki proizvodi datoteku koju sledeći čita i svaki se može ponoviti bez prethodnih — zato što je datoteka reči jedini izvor istine.



Tok obrade. Crveni korak je jedina obavezna ljudska tačka — prevod se ne pokreće automatski.

Memorija kartice je usko grlo: prepoznavanje traži oko 5 GB, prevod oko 8 GB, a ima 16 GB. Oba staju, ali bez rezerve. Pošto je pajplajn ionako sekvencijalan, model se oslobađa čim njegova faza završi.

5.1. Prepoznavanje govora

Model je `large-v3` u brzoj implementaciji, poluprecizno na kartici. Izbor je fiksiran i sklonjen sa ekrana: manji modeli jesu brži, ali su na srpskom osetno lošiji, a tiho spušten izbor daje lošiji prepis bez objašnjenja.

Model vraća reči sa vremenima. Bez toga cue-ovi dobijaju interpolirana vremena i titl „pliva" u odnosu na govor.

Parametri i razlozi

Parametar	Vrednost	Razlog
`language`	eksplicitno	automatska detekcija srpski redovno prepozna kao hrvatski i vrati ijekavicu
`word_timestamps`	uključeno	osnovni zahtev — bez vremena po rečima nema prelamanja
`condition_on_previous_text`	isključeno	glavna odbrana od petlji ponavljanja na dužim zapisima
`hallucination_silence_threshold`	isključeno	vidi upozorenje ispod
`compression_ratio_threshold`	2,4	detekcija ponavljanja
`temperature`	0,0 → 1,0	postepeno popuštanje kad segment padne

`vad_filter`	uključeno, prag 0,35	uklanja tišinu pre prepoznavanja

> **Filter halucinacija koštao je 28% sadržaja.** `hallucination_silence_threshold` je uveden kao dodatna zaštita od izmišljenog teksta. Kad segment proglasi sumnjivim, njegova grana preskače do kraja datoteke i tiho briše ostatak — bez reda u dnevniku. Čim je isključen, pokrivenost je skočila sa 55,9% na 83,8%, a broj reči sa 155 na 173. Ostao je kao izričita opcija sa upozorenjem, uz test koji pada ako ga neko vrati među podrazumevane.

Detekcija tišine

Filter tišine je ponuđen kao tri imenovana izbora, ne kao broj — prag nikome ne znači ništa dok ne pusti ceo prepis:

Izbor	Prag	Kada
normalno	0,35	blaže od standardnog 0,5 koje jede tiši govor
tih snimak	0,20	kada se sumnja da nešto nedostaje
isključeno	—	**podrazumevano**, vidi merenje ispod

> **Filter tišine je podrazumevano isključen, suprotno očekivanju.** Tri prolaza istog tihog zapisa dala su: prag 0,35 — 179 reči i 85,6% pokrivenosti; prag 0,20 — 180 reči i 87,9%; **isključeno — 189 reči i 88,9%**, uz osetno tačniji tekst (`Delikates burger` naspram `deli kates burdžer` , dve odvojene rečenice naspram spojenog fragmenta). Objašnjenje koje se nameće: na tihom zapisu filter seče delove govora koje model inače rekonstruiše iz konteksta. Odbrana od izmišljenog teksta ostaje na `condition_on_previous_text=False` i pragu kompresije, istim onim razlogom kojim je isključen i filter halucinacija. Kada je filter uključen a odbacio bi više od desetine zvuka, ispis predlaže poređenje sa isključenim — mera je udeo odbačenog zvuka, ne pokrivenost, jer pokrivenost meri koliko zapis uopšte sadrži govora (najveća ikad izmerena je 88,9%) i zato je kao prag beskorisna.

Posle svakog prepoznavanja alat prijavljuje **pokrivenost** — koliki je deo zapisa pokriven rečenicama — i nabraja praznine duže od tri sekunde sa vremenima. To je jedina zaštita od tihog gubitka sadržaja; inače se ne primeti dok se titl ne pusti uz sliku.

Glosar ulazi u prepoznavanje — i tu je zamka

Ključevi glosara idu modelu kao spisak reči koje može da očekuje, i time osetno popravljaju pogađanje imena. Ali ne idu samo na početku: da bi glosar preživeo ceo zapis, ulazi u svaki prozor od trideset sekundi.

> **Model vraća glosar tamo gde nema šta da čuje.** Na reklamnom zapisu od 32 sekunde, sa muzičkim džinglom na kraju, poslednjih deset sekundi prepisa bilo je doslovno pet termina iz glosara prethodnog posla: `Otvorena vrata, letnja radionica, OKC, Divčibare, Srbija` . Glosar je bio globalan i ulazio je u svaki nov posao, pa je materijal jedne organizacije curio u snimke druge.

> Otkriveno je poređenjem četiri prolaza istog fajla: sa punim glosarom 77 reči i ceo niz termina preko džingla; sa praznim glosarom 66 reči i nijedan termin. Popravka je **glosar vezan za posao** — svaki posao dobija svoju kopiju pri otvaranju, i prazan glosar je ravnopravan izbor.

Namerno upotrebljen, isti mehanizam je jedino što stvarno pomaže na dijalektu: reči i imena iz tog snimka, upisana u glosar posla pre prepoznavanja, model pogađa osetno bolje. Doobučavanje modela traži sate ručno označenog zvuka i nije razmatrano.

> **Filtriranje tišine i glosar se sudaraju, i to se vidi samo u njihovoj kombinaciji.** Četiri prolaza, svaki pet puta ponovljen:
>
> | | **pun glosar** | **prazan glosar** |
> |---|---|---|
> | filter isključen | 77 reči, izmišljen tekst preko džingla | 66 reči, druga izmišljotina |
> | filter uključen | **20–52 reči, svaki put drugačije** | **59 reči, najčistiji prepis** |
>
> Jedina ćelija koja nije ponovljiva je ona sa oba uključena. Filter seče zapis u kratke odsečke, u svaki ulazi glosar, i model na njima odustaje od dekodiranja pa vraća prompt. Filter sam po sebi radi uredno — na snimku sa muzikom čak najčistije, jer muziku ne pusti do modela.

Zato filter ostaje isključen: na govoru bez muzike gubi reči, a koristi samo tamo gde ima montiranih delova bez govora. Odluka se i ne traži unapred — udeo negovora meri se u svakom prolazu, pa izveštaj nudi ponavljanje sa filterom kad ga brojka opravda.

5.2. Jezičke normalizacije

Tri normalizacije idu nad datotekom reči, pre segmentacije, da sve posle njih radi sa čistim ulazom. Svaka beleži svoju izmenu u dnevnik.

Pismo

Model za srpski vraća čas ćirilicu, čas latinicu, ponekad pomešano u istoj datoteci. Izlaz se odmah svodi na latinicu i interno se radi samo njome: tokenizacija je bolja, a prevodioci su na latinici pouzdaniji. Ćirilica se dobija transliteracijom na kraju.

Ekavizacija

I kad je jezik izričito zadat, ijekavski oblici se probiju. Rešenje **nije regularni izraz**: pravilo „ije/je → e" uništilo bi `jesen`, `jedan`, `jezik`, `prijem`, `sjaj`. Umesto njega stoji kurirani rečnik u četiri sloja, od kojih se zaštita proverava prva:

Sloj	Značenje	Primer
zaštićeno	nikad se ne dira	`jesen`, `jezik`, `prijem`, `Mjanmar`
tačan oblik	cela reč	`prije` → `pre`

prefiks	reč počinje osnovom	`djec` → `dec`
bilo gde	osnova unutar reči	`vidje` → `vide`, hvata i `predvidjeti`

Tabele se pri učitavanju proveravaju na međusobne sudare — provera je već uhvatila da bi zaštićena `želja` blokirala `željeti`.

Spajanje elizija

Na francuskom model vraća razdvojeno: `j 'aimerais`, `c 'est`, `aujourd 'hui`. Prelamanje tada vidi `j` i `'aimerais` kao dve reči, pravilo protiv razdvajanja elizije nikad ne okine, i cue počne sa `'espère` bez svog `j`. Za francuski titl to je grubo.

Kratke osnove idu po pravilu, duže po spisku (`qu`, `jusqu`, `lorsqu`, `aujourd`, `puisqu`, `quoiqu`, `quelqu`, `presqu`). Nova reč uzima početak prve i kraj druge, a **manju od dve verovatnoće** — da spajanje ne sakrije nesigurnost koju editor boji. Mereno: 33 spajanja, 428 → 395 reči, nijedan token više ne počinje apostrofom.

5.3. Restauracija interpunkcije

Zarezi su glavni signal za tačku preloma unutar rečenice. Tekst bez njih daje loše prelome ma koliko algoritam bio dobar — nema šta da prepozna.

Model za prepoznavanje punktira nepouzdano: na jednom zapisu je uredno postavio znake u prvih pet rečenica pa prestao do kraja. Zato postoji uslovni korak koji tekst šalje jezičkom modelu uz zahtev da vrati **identičan niz reči**, sa dodatom interpunkcijom i velikim slovima.

Kada se pokreće

Odlučuje **gustina znakova**, ne prosečna dužina rečenice. Prosek vara: „Dobar dan. Hvala." ima 1,5 reči po rečenici i savršenu interpunkciju.

```
znakova kraja / 100 reči < 4,0  I  zareza / 100 reči < 8,0 → pokreni restauraciju
```

Uslov na zarez došao je iz trećeg merenja: zapis sa 3,4 znaka kraja na sto reči imao je **17,6 zareza**, sasvim dovoljno za prelamanje. Restauracija je svejedno pokrenuta i koštala 61 sekundu, od čega 33 bačene, uz pet od osam odbijenih odlomaka. Pošto prelamanje koristi zareze, oni sada ulaze u odluku. Izmereno razdvaja slučajeve čisto: francuski 2,5 (pokreće se), srpski 5,5 (ne pokreće se, i zaista ima 31 zarez). Prag je rečnik po jeziku, jer francuski i engleski imaju kraće rečenice i prirodno višu gustinu — iz dva merenja se ne izvodi jedan broj za sve. Gustina se ispisuje posle svakog prepoznavanja, i kad kapija ne okine, da bi se pragovi vremenom podesili po podacima.

Zaštita od prepravljanja

Odgovor se poredi sa originalom reč po reč, bez interpunkcije i veličine slova. Izmena sadržaja obara ceo odgovor. Dve vrste odstupanja prolaze, jer su pravopisne a ne značenjske:

Dozvola	Provera	Primer
razdvajanje reči	spojeni delovi moraju tačno dati original	`ya` → `y a`
promena oblika	zajednički prefiks ≥ 3 znaka, razlika ≤ 2 znaka	`généreuse` → `généreuses`
dijakritika	isključeno	`tres` → `très`

Svaki ustupak se beleži sa konkretnim rečima, pa se značenjska izmena odmah vidi. Na testnom zapisu: dva ustupka, oba pravopisna, i jedan odbijen odgovor — model je hteo da sredi ponavljanje `qui me qui me filme` iz prepoznavanja. To je izmena sadržaja i s pravom je odbijena.

Povlačenje na poslednji znak

Model svaki odlomak punktira kao zaokruženu celinu: zatvori ga tačkom, sledeći počne velikim slovom. Odatle lažni prelomi na granicama odlomaka — `...avant la pluie.` / `Nous avons rangé le matériel...`, gde je original bio jedna rečenica.

Rešenje je deterministično i ne traži poverenje u model: u svakom odlomku se nađe poslednji rečenični znak koji nije na samom kraju, prihvati se izlaz do tog mesta, a rep ide u sledeći poziv, gde ima svoj pravi nastavak. Veliko slovo prve reči vraća se na malo, ali samo ako je original bio mali, da vlastita imena ostanu netaknuta.

Ako bi rep bio veći od polovine odlomka, izlaz se prihvata kakav jeste uz upozorenje — inače bi se vraćanje vrtelo u krug.

> **Mereno na francuskom zapisu.** Pre povlačenja i dozvola: 102 s, 8 odbijenih odlomaka, 45% vremena bačeno, četiri lažna preloma. Posle: 60 s, 1 odbijen odlomak, 10% bačenog vremena, tri od četiri preloma nestala. Četvrti je ostao tačno tamo gde je zaštita presekla povlačenje — cena zaštite, vidljiva i prihvaćena.

5.4. Segmentacija

Reči se sastavljaju u rečenice po interpunkciji, uz zaštitu od skraćenica (`itd.`, `npr.`, `dr.`, rednih brojeva). Rečenica duža od petnaest sekundi lomi se na najvećoj pauzi, a kad su pauze jednake — na onoj najbližoj sredini.

> **Kvar koji je ličio na problem interpunkcije.** Na francuskom zapisu je svaka reč postala zasebna rečenica, trajanja 0,2–0,4 s. Očigledno objašnjenje — nema interpunkcije, nema na čemu da se lomi — bilo je pogrešno. Uzrok je bio izbor najveće pauze nad listom parova: kad su sve pauze jednake, a u tečnom govoru jesu, poređenje pada na drugi član para i bira najveći indeks. Rez je uvek padao na poslednjoj reči, pa je rekurzija ljuštila po reč sa kraja do kraja zapisa. Popravka je jedan red; nalaz stoji ovde zato što pokazuje koliko uverljivo pogrešno objašnjenje ume da izgleda.

Pravilo o petnaest sekundi prošireno je i na gotove titlove koji ulaze spolja, pošto je jedan nedosledno interpunktiran ulaz dao rečenicu od 15,96 s sa tri odvojene misli. Pauze između cue-ova merene su

kao dopunski signal granice (1,0, 1,5 i 2,0 s) i odbačene: preko onoga što trajanje već hvata donele su tačno jedan presek, i taj pogrešan. Mehanizam je ostao u kodu, isključen, sa upisanim merenjem.

Zaštitna mreža hvata krnje komade: rečenica kraća od tri reči ili od sekunde spaja se sa sledećom, osim ako se završava jasnom interpunkcijom. Rečenica u kojoj ijedna reč ima verovatnoću ispod 0,6 dobija oznaku `low_confidence`, koja u editoru pali boju.

Reči bez zvuka iza sebe

Postoji klasa izmišljenog teksta koju verovatnoća ne vidi uopšte. Na istom reklamnom zapisu poslednjih devet reči imalo je **trajanje tačno nula**, sve na istom trenutku, dve stotinke pre kraja:

```
 94  31.32-32.16  p=0.98  igre
 96  32.26-32.26  p=0.87  letnja
 97  32.26-32.26  p=0.98  radionica
 98  32.26-32.26  p=0.99  otvorenih
100  32.26-32.26  p=0.00  OKC
102  32.26-32.26  p=0.20  Divčibare
104  32.26-32.26  p=0.23  Srbija
```

Model je **siguran** u ono što je izmislio — `radionica` 0,98, `otvorenih` 0,99 — pa oznaka nesigurnosti ne okida. A reč bez ijednog uzorka zvuka iza sebe nije mogla biti čuta.

Pravilo zato ne gleda verovatnoću: **niz od dve ili više uzastopnih reči kraćih od 0,02 sekunde** prijavljuje se kao izmišljen, sa vremenima i tekstom. Interpunkcija se ne broji.

Prag niza	pogodaka	lažnih uzbuna
3 ili više	2	nijedna
2 ili više	**3**	**nijedna**

Mereno na trinaest poslova. Prag dva uzet je tek pošto je jedini kandidat za lažnu uzbunu — francusko `c'` `est` u ponovljenom `c'est c'est-à-dire` — nestao kad je merenje pomereno iza spajanja elizija, kako radi i sam pajplajn. Drugi pogodak van testnog zapisa bio je prava izmišljotina: `titrage ST' 501`, ostatak obrasca koji model nosi iz trening podataka.

Oznaka je **odvojena od oznake nesigurnosti** i razlikuje se bojom: nesigurne reči su žute, izmišljene crvene i precrtane. Jedna znači da model nije siguran, druga da je siguran u nešto čega nema.

Pravilo hvata samo deo. Na istom zapisu prvih deset izmišljenih reči imalo je razvučena vremena — `Otvorena` 2,34 sekunde — a to se ne da razlikovati, jer uredni snimci imaju reči i do 5,3 sekunde. Glosar po poslu ostaje glavna mera, ova je pomoćna.

5.5. Prelamanje u cue-ove

Srce alata i jedini deo koji nije trivijalan. Prelamanje je razlika između titla koji izgleda profesionalno i onog koji ne izgleda. Algoritam je namerno deterministčan — bez jezičkog modela, jer nedeterminizam i sporost ovde ne donose ništa.

Postupak: generišu se svi kandidati za tačku preloma, svaki dobije kazneni poen, bira se kombinacija sa najmanjim zbirom. Vremena cue-a dolaze iz stvarnih vremena prve i poslednje reči u njemu — ne dele se srazmerno broju znakova, jer prava vremena postoje.

Kazneni poeni

Situacija	Kazna	Zašto
red duži od dozvoljenog	1000 / znak	tvrdo ograničenje profila
razdvaja predlog od imenice	300	`u / kuću` je najvidljivija greška
razdvaja delove složenog glagola	300	`bi / došao`
enklitika na kraju ili početku reda	300	nema sopstveni naglasak
razdvaja pridev od imenice	200	
jedna reč sama u redu	400	vizuelno najgori ishod
brzina čitanja preko dozvoljene	100 / jedinica	gledalac ne stiže da pročita
prelom nije na granici klauze	50	
prelom iza veznika	10	prihvatljivo, ali ne idealno
prelom posle zareza	0	idealna tačka
neravnoteža redova	2 / znak	dodato posle merenja
prekratak cue	20 / znak	sprečava otcepljivanje fragmenata
svaki novi cue	20	blago protiv rafala kratkih cue-ova

Tabele funkcijskih reči postoje **po jeziku**, i to nije kozmetika: srpska enklitika ne sme ni da počne red, a engleski i francuski pomoćni glagoli slobodno počinju red (`he / is going`). U istom skupu engleski bi dobio zabranu koja u njemu ne postoji. Francuska elizija nije spisak nego pravilo: hvata svaki token koji se završava apostrofom, jer je elizija fonološka pojava.

Jezik koji nije u tabelama dobija samo opšta pravila, uz upozorenje u dnevniku — umesto tihog lomljenja bilo gde.

Profili

Prvi skup profila bio je tri varijante istog — 42, 37 i 47 znakova u dva reda — pa izbor nije nosio odluku. Zamenjen je sa tri profila koji se razlikuju po **obliku**:

Profil	Oblik	Brzina	Trajanje cue-a	Namena
tv	2 reda × 42 znaka	20	0,83 – 7,0 s	podrazumevani, klasičan titl
web	1 red, 10–20 znakova	20	0,50 – 4,0 s	vertikalni video

digital	isto kao `web`	20	0,50 – 4,0 s	društvene mreže: VELIKA SLOVA, bez interpunkcije

Promena profila ne pokreće obradu: titl se sastavlja iz sačuvanih rečenica za deo sekunde, pa se menja iz padajućeg menija, bez dugmeta.

Jednoredni profil traži druga pravila

Jedan red nije samo manja granica. Tri kazne iz dvorednog prelamanja tu mere nešto čega nema:

Kazna	U jednorednom profilu
jedna reč sama u redu	**isključena** — to je normalno stanje, ne greška
neravnoteža dva reda	**isključena** — nema drugog reda
prekratak cue po znakovima	**isključena** — dvadeset znakova je ceo cue
enklitika na kraju ili početku reda	**ostaje** — i dalje je prava greška, i vidljivija

Umesto njih stoji **donja granica dužine reda** kao meka kazna, 30 po znaku ispod deset, uz izuzetak kad je cela rečenica kraća od granice. Izuzetak je prvo bio preširok — važio je za svaki poslednji komad rečenice, a taj je kratak upravo zato što je prethodni rez bio loš — pa je rečenica od 21 znaka izlazila kao `Čao, Borise, šta` i `ima?`. Suženje ga je spustilo sa 21 na 12 rečenica sa jednom rečju na kraju.

> **Ravnomerna podela rečenice je merena i odbačena.** Očigledno rešenje za natpis od tri znaka jeste deliti rečenicu na jednake delove. Mehanizam je izgrađen i izmeren na trinaest poslova, sa četiri težine: menja sedam od pedeset devet rečenica, tri nabolje, dve nagore. Veće težine smanjuju broj kratkih redova, ali to plaćaju rezovima iza predloga (`vratili smo se do / kombija`) — najvidljivijom greškom u titlu, u jednorednom profilu vidljivijom nego inače, jer se dva dela pojavljuju u različitim trenucima.
>
> Mehanizam je ostao u kodu, isključen, sa upisanim merenjem — i sa razlogom: udeo meri pogrešnu osovinu. Cue `Čao,` nije loš zbog broja znakova nego zato što traje 0,12 sekunde: tri frejma, natpis trepne i nestane. Kazna za cue kraći od najkraćeg trajanja profila je verovatno ono pravo, i stoji kao sledeća stavka.

Preimenovanje koje reciklira ime

Nova podela je uzela ime `web` za nešto drugo. Posao sa upisanim `web` dobio bi posle preimenovanja sasvim drugi prelom od onog kojim je napravljen, a pseudonim ne pomaže — ne razlikuje staro značenje od novog.

Zato ide **jednokratna migracija** uz podizanje verzije zapisa o poslu: stari `netflix`, `tv` i `web` postaju `tv`, stari `digital` postaje `web`. Posao koji je već na novoj verziji se ne dira, pa novi `web` nikad ne postane `tv`. Svaka promena ide u dnevnik tog posla, sa razlogom.

5.6. Transliteracija i izlazne transformacije

U smeru ćirilica → latinica to jeste obična zamena znakova. Obrnuti smer je zamka: `lj`, `nj`, `dž` nisu uvek digrafi.

Latinica	Tačno	Naivno bi dalo
nadživeti	надживети	наџивети
injekcija	инјекција	ињекција
konjugacija	конјугација	коњугација
podžanr	поџанр	поџанр
Tanjug	Танјуг	Тањуг

Zato je transliteracija deterministička funkcija sa listom izuzetaka u kodu, ne biblioteka. Izuzeci pokrivaju prefikse `nad-`, `pod-`, `od-`, `pred-` i internacionalizme sa `nj`/`inj`; svaki primer iz tabele ima svoj test.

Ovaj korak nikad ne radi jezički model: transliteracija mora biti tačna i predvidiva, a to se od modela ne može tražiti.

Pismo, veličina slova i interpunkcija su transformacije izlaza

Tri izbora menjaju gotov titl a ne diraju rečenice: **pismo** (latinica ili ćirilica), **veličina slova** (normalno, VELIKA, mala) i **interpunkcija** (zadrži ili izostavi). Sva tri se primenjuju pri pisanju SRT-a, posle prelamanja, i menjaju se bez ponovne obrade.

Redosled nije proizvoljan. **Interpunkcija se skida poslednja, posle prelamanja**, jer je zarez najbolja tačka preloma u algoritmu, sa kaznom nula. Skinuta ranije, prelamanje bi ostalo bez glavnog signala baš u profilu gde je svaki znak dragocen.

U profilu `digital` izbacuje se	Ostaje
`.` `,` `;` `:` `?` `!` `…`, crte, navodnici, zagrade	apostrof i crtica **unutar reči**

Pravilo nije „skloni sve znakove" nego „skloni znakove između reči i na kraju reči, ostavi one unutar reči". Bez toga `c'est` postaje `cest`, a `rendez-vous` postaje `rendezvous` — to više nije izostavljena interpunkcija nego pokvarena reč. Znaci između cifara (`3,5`, `15:30`) ostaju, jer menjaju vrednost broja, a ne rečenicu.

Oznake u titlu — kurziv i položaj — ne dira nijedna od tri transformacije. Velika slova nad `<i>tekst</i>` dala bi `<I>TEKST</I>`, što deo plejera ne prepoznaje.

Jedna posledica je ostavljena namerno: prekoračenja se broje pre ovih transformacija, pa izostavljena interpunkcija skrati red i poneko prijavljeno prekoračenje u gotovom fajlu više ne postoji. Smer je bezbedan — prijavi se više nego što postoji, nikad manje.

6. Prevod

Prevod se pokreće klikom, nikad sam. Razlog je praktičan: prevod neispravljenog teksta prevodi i greške, pa se posle ispravljaju dve datoteke umesto jedne. Titl na jeziku originala je dostupan čim prepoznavanje završi.

Osnovno pravilo — prevodi se rečenica, ne cue

Prevod pojedinačnih cue-ova je najčešća greška u ovakvim sistemima. Cue je proizvoljan isečak rečenice; sam za sebe gubi rod, padež i vezu sa kontekstom. Zato se prevode **rečenice, sa po dve rečenice konteksta sa svake strane** koje se šalju ali ne prevode, a prelamanje se radi ponovo — nad ciljnim jezikom i njegovim pravilima.

Zaštita od pomeranja

Najgori kvar u prevodu titlova nije loš prevod nego **pomeren prevod**. Pošalje se deset numerisanih rečenica, model vrati devet, ostatak datoteke se pomeri za red i titl više ne prati sliku — a tekst pri tom izgleda savršeno.

Zato se traži numerisan izlaz u tačnom formatu i broj se proverava programski. Neuspeh vodi u smanjivanje: prepolovi odlomak, pa na dve rečenice, pa jednu po jednu. Posle dva neuspeha na jednoj rečenici upisuje se original sa oznakom i obrada ide dalje. Jedna rečenica nikad ne obara posao.

> **Brojevi koje model vidi počinju od jedan.** Odlomku se ne šalju stvarni identifikatori rečenica nego lokalni brojevi `1..n`, a mapiranje nazad drži kod. Razlog je izmeren: dok su brojevi bili stvarni, model je ispred njih dodavao svoje nabrajanje (`1. 28|And then we packed the tents…`), pa provera nije prepoznavala cifru i odbacivala je ceo odlomak. Na jednom poslu je to bilo 14 od 16 odbijanja. Kada se brojevi poklope, model nema šta da doda: **16 odbijenih odlomaka postalo je 0, broj zahteva 54 → 22, vreme 326 → 181 sekundu.**

Kada prevod nije prevod

Provera broja linija ne hvata slučaj kad model vrati izvorni tekst pod ispravnim brojem. To se dešava, i u gotovom titlu izgleda kao da je sve prošlo. Zato posle prevoda ide zasebna provera: rečenica je sumnjiva ako sadrži slova kojih u ciljnom jeziku nema (`ć`, `đ`, `š`, `ž`, `č` za francuski) ili je po rečima 80% ista kao original. Vlastita imena su izuzeta — bez toga su `Jelena Đurđević` i nazivi organizacija imali veći udeo takvih slova od pravih promašaja.

Izveštaj navodi **broj cue-ova**, ne samo rečenica: jedna neprevedena rečenica ume da pokrije deset cue-ova, a brojka „1" bi to sakrila. Te rečenice su u editoru crvene, i ručna ispravka skida oznaku.

Dopuna iz merenja: ako se ista greška ponovi i u manjem odlomku, polovljenje se prekida odmah — ne pomaže, samo troši vreme.

Glosar

Tabela termina po smeru prevoda, u upotrebi na dva mesta: ključevi idu modelu za prepoznavanje kao nagoveštaj, celi parovi u prevodni upit.

```
{
  "sr->en": {
    "Radionica otvorenih vrata": "Open Door Workshop",
    "animator": "activity leader",
    "sporazumevati se": "understand each other",
    "s obzirom na to da": "because",
    "Đurđević": "Đurđević"
  }
}
```

Poslednji unos nije greška: upisuju se i termini koje **ne treba menjati**, da ih model ne transliteruje ili „popravi".

> **Glosar je izmeren, ne pretpostavljen.** Poređenje istog modela sa istim parametrima, jedina razlika glosar: `Radionica otvorenih vrata` je bez glosara prevedena kao „Open Doors Workshop", sa glosarom tačno; `animator` kao „animator" pa „activity leader"; `sporazumevati se` kao „to reach an agreement" — pravno značenje umesto svakodnevnog — pa tačno. Tri od tri, i greška se vraća čim se unos ukloni.

Izbor modela

Mereno na devet parova rečenica iz stvarnog materijala, sa ručno napisanim referentnim prevodom za svaki, ocena ručna u tri stepena — automatske mere na ovako malom uzorku ne znače ništa.

Model	Veličina	Brzina	Dužina vs. referenca	Nalaz
gemma3:12b	7,8 GB	37 tok/s	1,03×	izabran — bolje čuva nijanse, sažetiji
qwen3:14b	9,7 GB	35 tok/s	1,06×	dostupan kao alternativa

Manji model je pobedio na sve tri osovine i usput oslobodio 2 GB na kartici, što ostavlja prostor za širi kontekst.

Prvi prolaz je pokazao da je izabrani model 2,4 puta sporiji — neočekivano za manji model. Bilo je to prvo pokretanje posle preuzimanja, kad se osam gigabajta čita sa diska; na toplom kešu razlika je nestala. Zato brzina modela sada ulazi u redovan ispis.

Tri tehnička uslova

Tri stvari moraju biti tačno postavljene, inače sistem tiho ne radi:

- **Isključeno rezonovanje.** Model podrazumevano „razmišlja" pre odgovora, što za prevod znači sedam puta sporiju obradu bez koristi. Provera je dvostruka, jer novije verzije rezonovanje vraćaju u zasebnom polju, ne u oznakama.

- **Izričita veličina konteksta.** Podrazumevanih 4096 tokena servis **tiho odseca**, bez greške i traga. Vrednost se posle prvog poziva čita nazad i poredi.
- **Provera nepoznatih polja.** Servis tiho prihvata izmišljena polja: greška u imenu opcije ne ostavlja trag. Zato se primenjene vrednosti čitaju nazad, ne pretpostavljaju.

Pivot preko trećeg jezika

Za parove sa slabom direktnom spregom (srpski → francuski) postoji i put preko engleskog. Oba puta stoje i biraju se podešavanjem; odlučuje merenje na stvarnom materijalu. Glosar za drugi skok izvodi se iz postojećih smerova gde može, a ako ostane prazan, upozorenje kaže da druga polovina puta ide bez rečnika.

7. Prevod postojećeg SRT-a

Drugi način upotrebe, dodat posle prvog meseca: umesto zvuka, ulaz je gotov titl. Povod je konkretan — titl na jeziku originala često nastane van ovog alata, ručno doteran u montaži, sa vremenima podešenim uz sliku. Kad za njega zatreba prevod, sve urađeno mora ostati netaknuto.

> **Tvrda garancija.** Broj cue-ova i sva vremena u izlazu identični su ulazu. Ne menja se ništa osim teksta. Provera se izvodi pre upisa: ako se tajming razlikuje, titl se ne zapisuje, a postoji i test koji poredi ulazni i izlazni fajl red po red.

Zašto se ne prevodi cue po cue

Cue je proizvoljan isečak rečenice i sam za sebe gubi rod, padež i vezu sa prethodnim. Zato postupak ima tri koraka:

1. **Sastavljanje.** Rečenice se sklapaju iz cue-ova po interpunkciji. Jedna rečenica se često prostire kroz više cue-ova, a jedan cue ume da nosi kraj jedne i početak druge.
2. **Prevod.** Prevode se cele rečenice, sa kontekstom, kao i inače.
3. **Raspoređivanje nazad.** Prevedena rečenica se deli na onoliko delova koliko je original imao cue-ova, sa istim udelom znakova po delu.

Tačke deljenja bira isto skorovanje kao prelamanje — iste kazne i iste tabele po jeziku. Razlika je u tome što su granice ovde zadate, pa je dodata kazna za odstupanje od ciljnog udela.

Profil se izvlači iz ulaza, ne nameće se

Prva verzija je merila prevod standardnim profilom i prijavila 47 prekoračenja od 204 cue-a. Merenje nad samim ulazom pokazuje zašto ta brojka ne znači ništa:

Mera	Ručno doteran original	Profil `netflix`
najduži red	51 znak	42
redova preko 42 znaka	26 od 219	—
najveći CPS	27,9	20
cue-ova preko 20 CPS	18 od 204	—

Autorov sopstveni titl, prihvaćen i isporučen, probija standardni profil na 26 mesta po dužini reda i 18 po brzini. Mereno tim profilom, prevod se poredi sa normom koju ni original ne poštuje.

Zato je podrazumevan **profil izveden iz ulaznog fajla**. Vrednosti idu sa 95. percentila, ne sa maksimuma: maksimum pretvara jedan izuzetan red u normu i gura 17% prevedenih redova preko 42 znaka, više nego u originalu (12%):

Profil	Redova preko 42 zn.	Prekoračenja	Od toga gore od originala
original (ulaz)	12%	—	—
netflix	0%	47	44
maksimum (51 / 27,9)	17%	8	8
95. percentil (47 / 21,4)	**11%**	**35**	**33**

Izveštaj od tada meri ono što treba: **koliko je cue-ova teže za čitanje nego isti cue u originalu.** Uz svaki prijavljeni stoji i vrednost pre prevoda.

Struktura prekoračenja je uvek ista

Na dva posla isto: **sva prekoračenja su brzina čitanja, nijedno dužina reda.** Nije slučajnost nego posledica postavke — vremena su fiksna, prevod je duži, pa brzina mora da poraste. Prelamanje to ne rešava: ono raspoređuje tekst, ne skraćuje ga.

> **Koliko je duži, izmereno je i razlika među jezicima je velika.** Odnos zbira znakova u prevedenim cue-ovima prema zbiru u originalnim, na poslu od 320 cue-ova: **francuski 17%, engleski 6%.** To objašnjava razliku koja je dotad samo konstatovana — 59 prekoračenja na francuskom prema 35 na engleskom nije svojstvo posla nego jezika. Merenje je ponovljeno nad tekstom rečenica i nad prelomljenim titlom, sa odstupanjem do 0,1 poena, i nad skupom bez rečenica koje su ostale neprevedene, sa odstupanjem do 0,2 poena. Do ovog merenja je u dokumentu stajala procena „15 do 20 procenata", preuzeta iz opšteg znanja a ne sa ovog materijala.

Skraćivanje prekoračenja

Zato postoji drugi prolaz kroz model, na dugme i nikad sam. Šalju se samo rečenice čiji su cue-ovi gori od originala, uz izvorni tekst i granicu u znakovima.

Jezik	Pokušano	Prihvaćeno	Izlazi iz prekoračenja	Prosečno skraćenje
francuski	47	36	38 od 59	27,6 zn. (26%)
engleski	29	24	23 od 33	22,6 zn. (29%)

Predlog prolazi samo ako je stvarno kraći, ako je brzina pala i ako nije izgubio termin iz glosara. Ni to nije dovoljno.

> **Model seče više nego što se traži, i tu se gubi značenje.** Za potrebnih 1–2 znaka ume da skrati i 40. Medijana je 2,15 puta više od traženog, i tri formulacije zahteva su merene da se to smanji: „kraće za najmanje N" (2,73×), opseg (2,36×) i apsolutna granica „najviše X znakova" (2,15×, u upotrebi). Čitanjem svih prihvaćenih predloga: oko tri četvrtine je čisto — izbačene su poštapalice i ponavljanja; oko desetine menja značenje; ostatak gubi sadržaj, na primer šalu koja je bila poenta rečenice. Zato se ništa ne upisuje bez pregleda, a predlozi skraćeni znatno više od traženog stoje bez kvačice i moraju se uključiti ručno.

Tipografija po jeziku

Izlaz prolazi kroz obradu zavisnu od ciljnog jezika. Francuski traži nerazlomljivi razmak pre `? ! : ;` i unutar `« »` — bez toga titl svakom francuskom čitaocu izgleda pogrešno, kao nama `reč ,`. Ti razmaci ulaze u dužinu reda pre prelamanja, da ne probiju profil naknadno.

> **Navodnici su se raspadali, i uzrok nije bio u modelu.** U jednom poslu je prevod izašao sa `"Ringe ringe raja" "` u jednom cue-u i `Ringe raja sa ""` u sledećem. Model je vratio uredan tekst; pokvarilo ga je raspoređivanje. Tokenizer odvaja pravi navodnik od reči i ne zna otvara li ili zatvara citat, pa je rez smeo da padne između navodnika i reči. Popravka: pre raspoređivanja svaki pravi navodnik postaje usmereni oblik ciljnog jezika, a oni se lepe za reč i ne mogu se razdvojiti.

Šta ovaj režim ne može

- **Nema slušanja ni bojenja po sigurnosti** — nema zvuka ni verovatnoća. Crveno su samo rečenice čiji cue probija profil i gori je nego u originalu.
- **Kurziv preko dela rečenice se gubi.** Posle prevoda se ne može pouzdano vratiti na isto mesto, pa se cue prijavljuje umesto da se pogađa. Cue ceo u kurzivu ostaje u kurzivu.
- **Nedosledna interpunkcija u ulazu pravi greške.** `Ja sam Marko` bez tačke, pa `Imam 12 godina`, daje rečenicu u kojoj model čita `Imam` kao prezime: `Je suis Marko Imam`. Rešenje je u ulazu, ne u alatu.

8. Ekrani aplikacije

Aplikacija se otvara dvoklikom, radi u pregledaču bez vidljivog terminala i stoji u sistemskoj traci. Druga prečica ne pokreće drugi proces nego samo otvara pregledač. Datoteka sa brojem procesa ne služi za proveru, jer preživi pad i laže; ni otvoren port nije dovoljan — tuđa aplikacija na istom portu jednom je navela alat da zaključi da već radi i otvori pregledač na nju. Zato se pita ko odgovara na portu, i ako to nije Subtitis, uzima se prvi slobodan iznad.

Prvi interfejs je bio tabela polja bez hijerarhije; posle meseca upotrebe prepravljen je iz temelja, u devet krugova u jednom danu. Od tog posla nisu ostali pojedinačni ekrani nego **četiri pravila** — vrednija od rasporeda, jer se po njima proverava svaki nov deo.

8.1. Četiri pravila interfejsa

Pravilo	Zašto
Objašnjenje je ikonica i prozorčić, nikad tekst na stranici	tekst koji uvek stoji gura sadržaj i zbija se u zid; prozorčić lebdi i ništa ne pomera
Ispod jedne trake najviše jedan red teksta	kad svako polje nosi svoje objašnjenje, ispod trake od četiri polja stoje četiri pasusa i ništa se ne čita
Radnja ne pomera pogled	isti skrol, isto fokusirano polje, iste otvorene trake posle svake radnje
Dugme kaže šta radi	potvrde idu kroz sopstveni prozor; nativni nosi adresu servera u naslovu i dugmad na engleskom

> **Pravilo se vraća dok se prijavljuje kao mesto.** Ista stavka — objašnjenje kao traka umesto kao ikonica — popravljana je pet puta zaredom, jer je svaki put pokazana na jednom ekranu. Prestala je tek kad je formulisana kao pravilo, sa obavezom da se prođe svaki šablon i testom koji pada ako se negde vrati. Isti test je odmah uhvatio dva mesta koja niko nije prijavio.

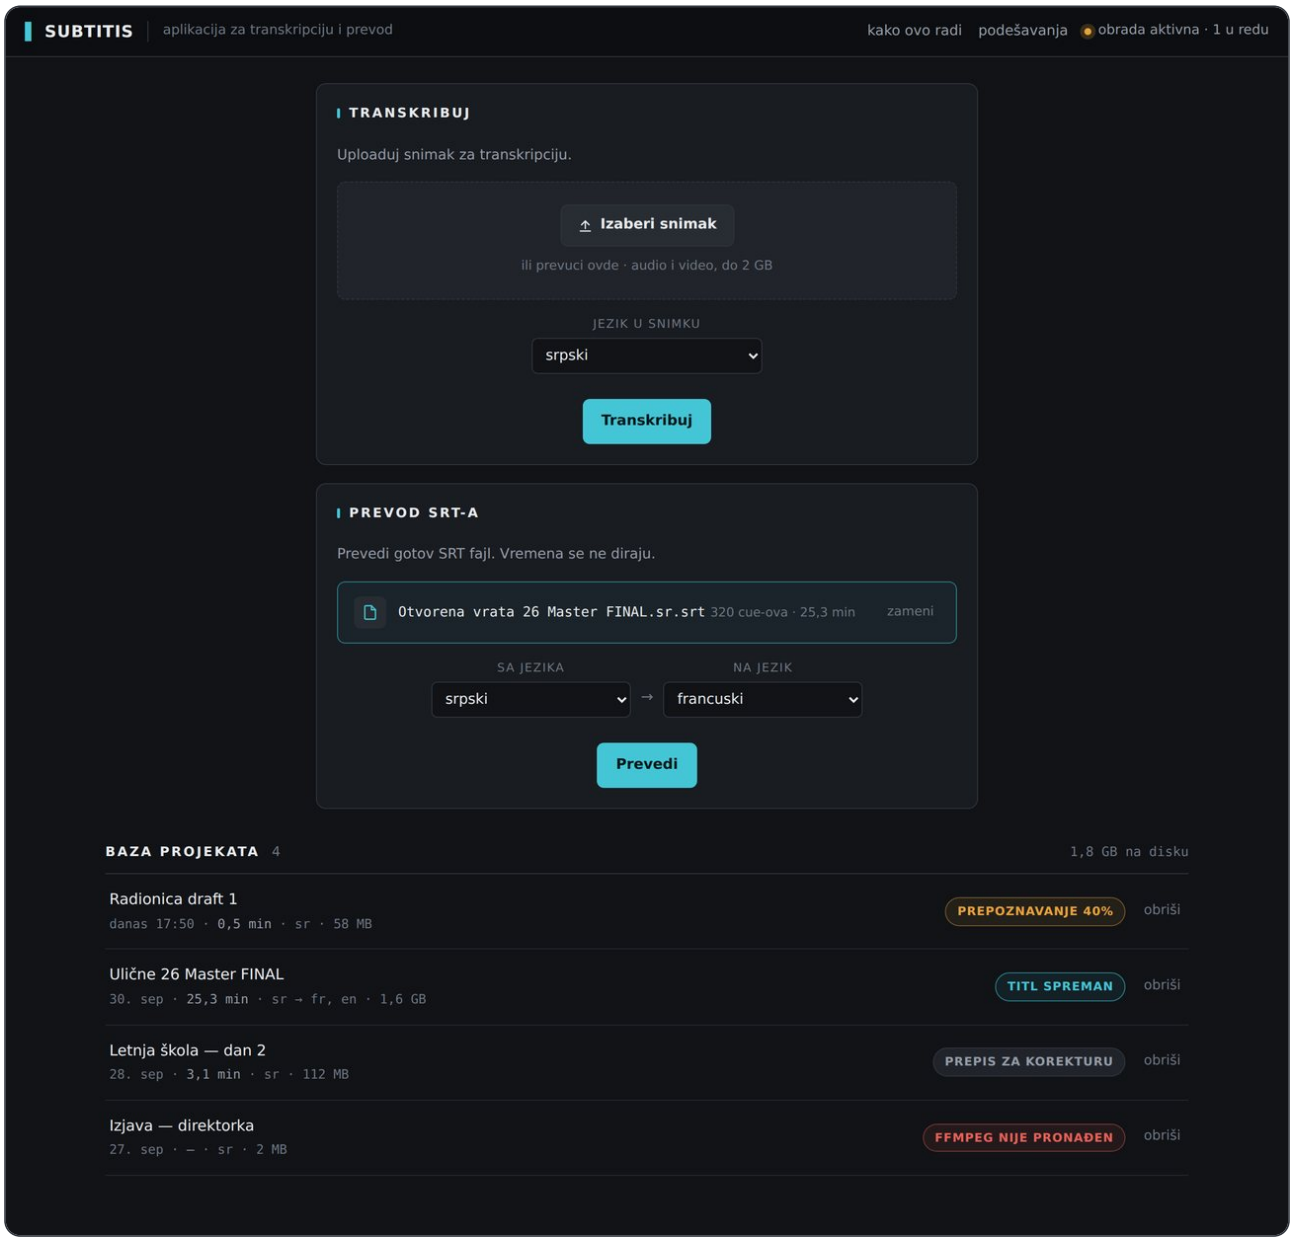
8.2. Početni ekran

Dva ravnopravna ulaza, jedan ispod drugog: **Transkribuj** (zvuk ili video kroz pun pajplajn) i **Prevod SRT-a** (gotov titl, sa očuvanim vremenima). Drugi je ranije stajao kao treći blok nadole i delovao kao sporedna funkcija, iako je polovina posla.

Svaki ulaz ima polje za datoteku, izbor jezika i jedno dugme. **Profil, glosar i filter tišine nisu na početnoj**: profil ne pokreće obradu pa pripada stranici projekta, odluka o filteru se donosi kad se vidi udeo negovora, a glosar je sveden na jedan izbor u podešavanjima. Polje za termine iz konkretnog snimka ostaje, sklopljeno — ono mora da postoji pre prepoznavanja, inače snimak na dijalektu ide dva puta.

Ispod je **Baza projekata** — tako se zovu, ne „poslovi" — u okviru sa svojim skrolom. Svaki red nosi ime datoteke kao naslov, a ispod sitno datum, trajanje, jezike i zauzeće. Mašinski identifikator se ne prikazuje nigde; nikad ništa nije govorio. Status je pilula koja gori samo kad treba: obrada je žuta i pulsira, greška crvena i sa stvarnim razlogom umesto reči `error`, gotov projekat miran.

> **Lista koja se sama osvežava bila je uzrok tri kvara odjednom.** Zamena celog bloka na tri sekunde vraćala je skrol na vrh dok se lista čita, gutala brisanje (forma zamenjena usred potvrde, pa projekat ostaje) i držala stalan pritisak na datoteke. Sada lista **miruje dok nijedan projekat nema zadatak**, a kad nešto radi, menjaju se samo pilule statusa.



Početni ekran: dva ravnopravna ulaza, baza projekata ispod. Tamna tema jer alat stoji pored Premierea i Resolvea.

8.3. Stranica projekta

Jedna kolona, odozgo nadole, redom kojim se radi:

Odeljak	Sadržaj
zaglavlje	ime, status, trajanje, jezik
trake upozorenja	izmišljene reči (crveno, sa tekstom i vremenom); udeo negovora (žuto, sa dugmetom za ponavljanje sa filterom)
editor	traka izlaznih izbora, red sa objašnjenjem profila, rečenice sa prelomom ispod svake
za preuzimanje	svi gotovi titlovi, sa oznakom jezika i pisma, brojem cue-ova i veličinom
prevod	ciljni jezik i dugme
izveštaj o obradi	faze sa trajanjima levo, izmerene vrednosti desno, pa ponavljanje prepoznavanja

Upozorenja stoje **iznad** teksta, ne pored njega: ono o izmišljenim rečima kaže tačno koje su i gde, a ono o udelu negovora nudi ponavljanje sa filterom odmah ispod brojke koja ga opravdava. Izveštaj je na dnu jer se gleda jednom, kad nešto ne valja.

Dugme za prevod je u boji, jedino na stranici — ono pokreće model na nekoliko minuta. Sve ostalo se izvršava u deliću sekunde i ne traži dugme.

8.4. Editor i prelom ispod rečenice

Editor je jedini ekran na kome se provodi vreme. Red je **rečenica**, ne cue: cue-ovi su izvedeni iz profila, pa bi uređivanje po cue-u značilo da svaka promena profila briše ispravke.

Odatle i najskuplji nesporazum u projektu: **promena profila, pisma ili veličine slova menja titl, a u editoru stoje rečenice.** Tekst ostaje isti, izmena se ne vidi, pa izgleda da izbor ne radi. Prijavljeno tri puta kao kvar, a funkcija je svaki put radila.

> **Rešenje je prikaz, ne promena modela.** Ispod svake rečenice stoje cue-ovi nastali iz nje, tačno kako će biti u datoteci — prelom redova, pismo, veličina slova, interpunkcija i vreme svakog cue-a. Rečenica iznad ostaje latinicom dok prelom ispod stoji ćirilicom, ako je takav izbor, pa se razlika između izvora i izlaza vidi jednim pogledom. Cue koji probija profil ili je prekratak obojen je i tu, pa se odmah zna koja rečenica pravi problem.

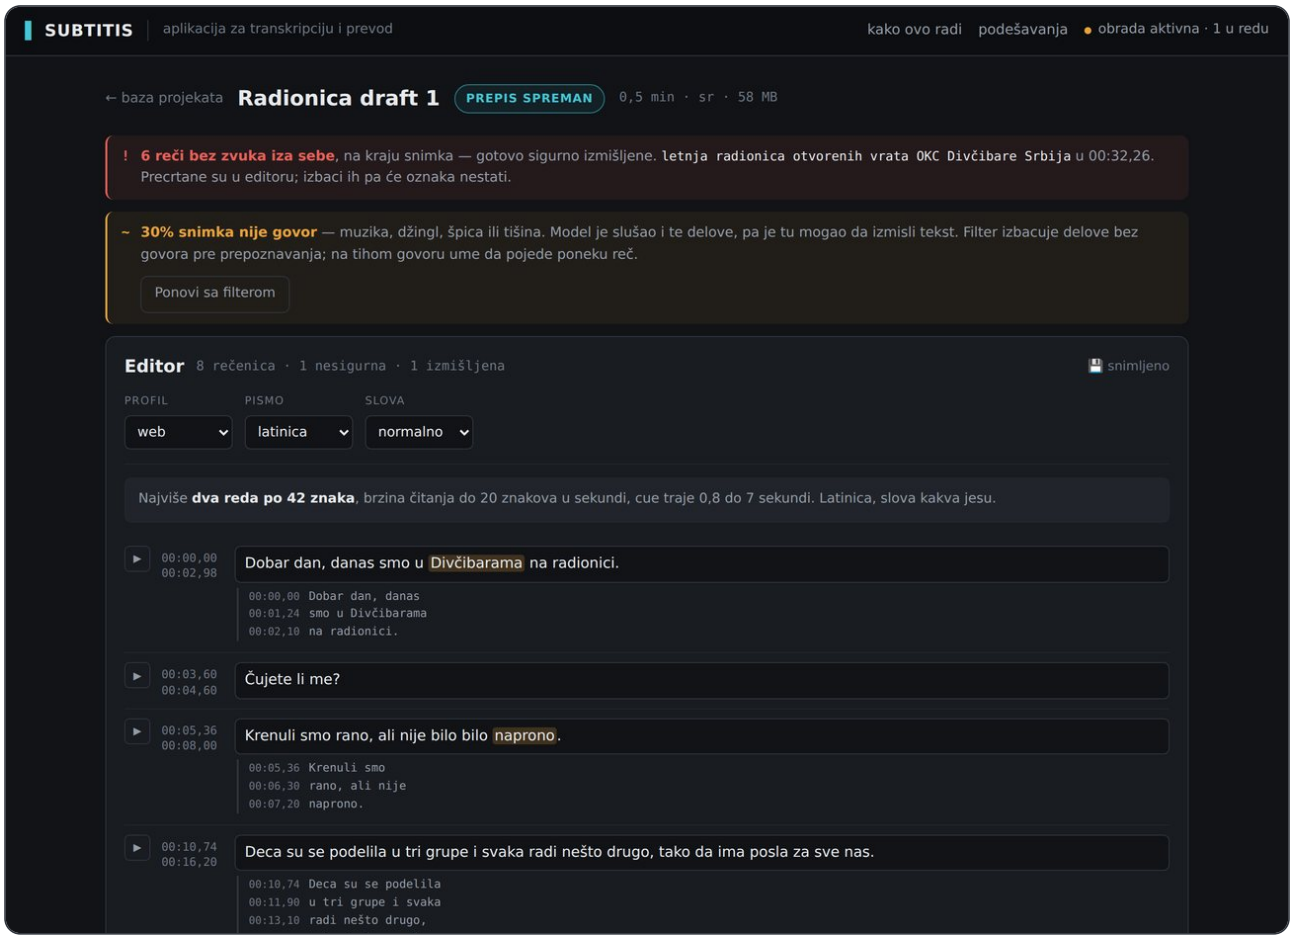
Prikaz se gasi prekidačem, jer na nekoliko stotina rečenica udvostručuje visinu liste.

Nijedna izmena ne čeka na dugme

Prelamanje je deterministično, ne poziva model i traje deo sekunde — na satu prepisa od 1683 rečenice oko 0,9 s. Dugme je zato uklonjeno: **promena bilo kog izbora prelama odmah**, a **izlazak iz polja sa izmenjenim tekstom snima i prelama**. Osvežava se samo deo sa prelomom, pa ni skrol ni fokus ne mrdaju.

Stanje snimanja nosi ikonica diskete: prigušena kad je sve snimljeno, u boji kad ima nesnimljenog. Rezervna kopija se pravi najviše jednom na pet minuta, pa ispravka svake reči ne stvara svoju verziju.

Usput je nađeno da je snimanje ispravke do tada prelamalo podrazumevanim profilom, šta god da je stajalo u traci. Verovatno uzrok dela ranijih prijava da promena profila „ne radi": radila je, a prvo sledeće snimanje ju je tiho vraćalo.



Stranica projekta: upozorenja iznad teksta, editor sa prelomom ispod svake rečenice, bez dugmeta za prelamanje.

8.5. Podešavanja

Podrazumevani profil, ciljni jezik, model, put prevoda (direktno ili preko engleskog), rok za brisanje radne kopije zvuka, šta nov projekat dobija kao glosar, i sam glosar. Svako podešavanje menja ponašanje bez ponovnog pokretanja, a ekran kaže kad promenljiva okruženja nadjačava vrednost — da se ne menja ono što se ne primenjuje.

8.6. Objašnjenja u interfejsu

Alat je mesec dana koristio samo autor, kome je svako polje bilo jasno jer je sam odlučivao šta u njemu stoji. Čim je trebalo zamisliti nekog drugog pred istim ekranom, pokazalo se da gotovo nijedna odluka nema vidljiv razlog.

Objašnjenja su u **dva sloja**: jedan red koji kaže šta da izabereš, i iza ikonice razlog sa izmerenim brojevima. Uz to stoji stranica Kako ovo radi, sa oba toka u koracima i tabelom čestih problema.

> **Devet od dvadeset pripremljenih tekstova nije se slagalo sa kodom.** Pisani su prema ovom dokumentu, ne prema izvoru, pa je provera pri ugradnji našla: dugme opisano a nikad napravljeno; profil sa pogrešno upisanim najvećim trajanjem; oznaku opisanu kao narandžastu iako je žuta; potvrdu koja postoji samo u

> komandnoj liniji. Isti obrazac koji se kroz ceo projekat ponavljao u kodu, prenet na dokumentaciju: **uverljiv opis nije provera.** Otuda pravilo da se tabele u interfejsu grade iz stvarnih datoteka profila i podešavanja, a ne prepisuju.

9. Funkcionalna pravila

Pravila koja važe kroz ceo sistem, nezavisno od ekrana na kom se vide.

Izvedene datoteke se uvek mogu regenerisati

Promena profila ili pisma ne pokreće ni prepoznavanje ni prevod; nov ciljni jezik ne pokreće prepoznavanje. Titl se iz sačuvanih rečenica sastavi za sekundu, puna obrada traje minutima.

Ručna ispravka se nikad ne pregazi

Datoteka sa oznakom ljudske izmene ne prepisuje se automatski. Ponovno prepoznavanje nad takvim poslom traži izričitu potvrdu, uz rezervnu kopiju. Provera ide posle prepoznavanja, ne pre — radije jedan uzaludan prolaz nego pregažene ispravke.

Ispravljen tekst zadržava prava vremena

Ispravljen tekst se poravnava sa originalnim tokenima, pa nepromenjena mesta zadržavaju stvarna vremena; interpoliraju se samo dodati tokeni. Padne li udeo poravnatih tokena ispod 60%, rečenica dobija oznaku degradiranog poravnanja i upozorenje u dnevniku — tiho loše poravnanje se inače otkrije tek u plejeru, u najgorem trenutku.

Neuspeh prekida zavisne zadatke

Pad jedne faze obeležava posao kao neuspešan i preskače zavisne zadatke, umesto da se prelama nad nepostojećim rečenicama i prijavi „gotovo". Preskočeni zadaci se vide, sa razlogom.

Prazan rezultat je greška

Prepoznavanje sa nula reči nije uspeh sa praznim titlom nego greška sa uputstvom. Pravilo je uvedeno pošto je jedan prazan zapis prošao ceo tok i dao titl od nula bajtova označen kao gotov.

Dnevnik je uvek tačan, konzola sme da izgubi kvačicu

Datoteka dnevnika je uvek u punom kodnom rasporedu. Ispis u konzolu pada na zamenu znakova, pa na tiho odustajanje.

> **Kodni raspored konzole rušio je snimanje ispravki.** Dnevnik je išao pravo na standardni izlaz, a konzola na Windowsu koristi zapadnoevropski raspored bez ć, š, đ, ž — dakle bez skoro svake poruke na srpskom. Svaki takav ispis rušio je ceo zahtev, usred snimanja korekture, uz poruku koja nema veze sa uzrokom. U režimu bez terminala, uvođenom istog dana, aplikacija bi pukla na prvoj poruci. Nađeno pri probi povratka na raniju verziju.

Posao se može obrisati i dok radi

Radna kopija zvuka se ne briše dok posao ima zadatak — inače bi zapis nestao usred prepoznavanja. Sam posao može: brisanje otkazuje zadatak, a obrada staje na prvoj prirodnoj tački, između delova,

nikad usred poziva modelu. Prva verzija je brisanje zabranjivala potpuno, pa obrada pokrenuta greškom nije imala kako da se zaustavi.

Prekid namerno nije ista vrsta greške kao ostale: te se ponegde hvataju da bi se nastavilo, pa bi prekid bio progutan. Posle prekida obrada ne pada nego prelazi na sledeći zadatak i još jednom briše direktorijum — zadatak ume da upiše dnevnik posle brisanja, a na Windowsu se otvorena datoteka ne može obrisati dok je ne pusti.

Pisma i jezici se proveravaju na serveru

Izbor pisma postoji samo kad je ciljni jezik dvopismen. Server ne veruje interfejsu: ćirilica nad jezikom koji je nema odbija se jasnom porukom u interfejsu, ne sistemskom greškom.

10. Izlaz, disk i rezervne kopije

Format titla

Standardni SRT: redni broj, vremenski opseg, tekst, prazan red. Kodiranje je puni raspored bez oznake na početku datoteke, prelomi redova u obliku koji Windows plejeri očekuju. Oboje je izvor tihih problema ako se pogreši.

Imenovanje prati standard oznaka jezika, sa pismom gde treba. Ime ne nosi profil: promena profila prepisuje datoteku, a stranica projekta kaže kojim je napravljena. Zatrebaju li ikad dve verzije uporedo, ime će morati da nosi i profil.

Zauzeće diska

Radna kopija zvuka je najveći trošak, oko 115 MB po satu zapisa. Treba samo dok traje korektura, jer se iz nje seku isečci za slušanje.

Mera	Vrednost	Razlog
ograničenje otpremanja	2 GB	nedovršeno otpremanje se briše
rok brisanja radne kopije	7 dana	automatski, pri pokretanju i na svakih 6 sati
brisanje posla	briše ceo direktorijum	uz potvrdu koja kaže koliko se oslobađa

Čišćenje ide periodično, ne samo pri pokretanju: aplikacija ume da radi nedeljama bez prekida, pa bi „pri pokretanju" značilo nikad. Svako brisanje ide u dnevnik posla.

Rezervne kopije

Pre svake izmene rečenica pravi se kopija sa vremenskom oznakom i brojačem — puna sekunda je preniska rezolucija, pa su dva snimanja u istoj sekundi davala isto ime i drugo je tiho pregazilo prvo. Sortira se po vremenu i brojaču, ne po imenu.

Projekat je u sistemu za verzionisanje, bez radnih datoteka, zavisnosti i ulaznih zapisa. Verzije zavisnosti su zaključane u trenutku kad je kombinacija potvrđeno radila, jer je sprega između biblioteke za prepoznavanje i biblioteka kartice osetljiva na nadogradnje.

11. Tehnička osnova

Izbor tehnologija

Sloj	Izbor	Razlog
server	FastAPI	lagan, asinhron, jednostavan za jednog korisnika
stanje	SQLite	bez zasebnog servisa; jedan korisnik, jedna mašina
prikaz	Jinja2 + HTMX	bez koraka izgradnje, bez paketa zavisnosti
prepoznavanje	faster-whisper, large-v3	vremena po rečima, dobra brzina na kartici
jezički model	Ollama, gemma3:12b	izabran merenjem; alternativa dostupna
zvuk	ffmpeg	ulaz bilo kog formata, uključujući video

Nema Reacta ni koraka izgradnje. Za alat koji koristi jedan čovek to bi bio teret veći od koristi: svaka izmena interfejsa je izmena jedne datoteke koja odmah radi.

Procesi i memorija

Obrada je nit unutar servera, ne zaseban proces — korisnik ne treba da zna da ih ima dva. Zasebna komanda ostaje za razvoj. Nit ne zadržava gašenje: petlja čeka na događaj, ne na istek vremena, i pri gašenju se čeka najviše dve sekunde.

Otkucaj koji hrani indikator „obrada aktivna" ide iz zasebne niti na pet sekundi. Da ga kuca glavna petlja, indikator bi pocrveneo usred svakog dužeg prepoznavanja. Nasilno ubijen proces ne stigne da obriše otkucaj, ali indikator pocrveni posle dvadeset sekundi.

Modeli se nikad ne drže u memoriji istovremeno; posle svake faze model se oslobađa, provereno praćenjem zauzeća kartice.

Otpornost na kvarove

Tri klase problema su rešene tako da se ne ponove:

- **Nalaženje spoljnih alata.** Redom: podešavanje, putanja sistema, poznate lokacije instalacije. Razvojno okruženje drži kopiju putanja od trenutka pokretanja i ne vidi kasnije instalacije, pa je alat bio „nedostupan" iako uredno instaliran.
- **Beleženje neuspeha.** Svaki korak beleženja je zasebno zaštićen, jer i sam upis greške ume da baci izuzetak i obori petlju obrade.
- **Provera stvarno primenjenih vrednosti.** Parametri jezičkog modela se čitaju nazad iz servisa i porede, umesto da se pretpostavi da su primljeni.
- **Pokretanje bez konzole.** U režimu bez terminala standardni izlaz ne postoji, pa svaki ispis baca izuzetak — i onaj iz tuđeg koda, pre ijednog sopstvenog reda. Pokretanje zato pre svega ostalog

podmeće izlaz u datoteku i upisuje svaki neuhvaćen izuzetak sa punim tragom. Bez toga prečica na radnoj površini ne radi, a nigde se ne vidi zašto.

Testovi

Hiljadu sto šezdeset automatskih testova pokriva **87% naredbi**, sa težištem na modulima gde je greška tiha: prelamanje, transliteracija, segmentacija, ekavizacija, spajanje elizija, provera odgovora modela.

Nekoliko testova su brane koje pamte skupo plaćene nalaze. Najizrazitiji proverava da filter halucinacija nije vraćen među podrazumevane parametre, sa objašnjenjem u samom testu da je gutao rep zapisa i koštao 28% pokrivenosti.

> **Broj testova nije pokrivenost, i razlika je bila ozbiljna.** Pri hiljadu sto četrdeset testova izmerena pokrivenost je prvi put: `run_transcribe`, glavna faza alata i funkcija koja se najviše menjala, bila je na **1%**. Nijedan test nije prolazio kroz nju, jer traži model i grafičku karticu — a baš zato je svaka izmena u njoj mogla da prođe nezapaženo do prvog stvarnog posla.
>
> Popravka nije bila deljenje funkcije od 370 linija nego test koji podmeće **samo četiri spoljne stvari** — pripremu zvuka, merenje govora, prepoznavanje i jezički model — a ostatak pušta kroz pravi kod i proverava ishode: nastale datoteke, broj reči i rečenica, oznake, faze i redove u dnevniku. Tri ulaza biraju tri različite grane: srpski bez znakova sa ijekavicom, francuski sa razdvojenim elizijama, i rep od pet reči bez zvuka. **1% → 88%**, bez ijedne izmene koda.

Isto merenje je pokazalo i da put prevoda preko engleskog nikad nije bio pokrenut nijednim testom, iako postoji kao podešavanje. Provera je potvrdila da radi onako kako je ovde opisano — tvrdnja je bila tačna, samo neproverena.

Kuriozitet: jedan generator testova upisao je stvarni upravljački bajt umesto oznake granice reči u obrazac za pretragu, pa su tri testa padala bez vidljivog razloga. Nađeno prikazom nevidljivih znakova.

12. Izmereni rezultati

Sve vrednosti su izmerene na stvarnom materijalu — izjavama snimljenim na terenu, na srpskom i francuskom — ne na sintetičkim uzorcima. Gde je uzorak mali, to je rečeno.

Prepoznavanje govora

Mera	Srpski	Francuski	Napomena
odnos prema stvarnom vremenu	~8×	~8×	sat zapisa za oko 7 minuta
reči sa niskom verovatnoćom	3,5%	—	uglavnom imena i stručni termini
pokrivenost	83,8%	92,5%	ostatak je govor van mikrofona
doslednost pisma	bez izuzetka	—	normalizacija nije imala posla
ekavizacija	4 izmene	—	na 173 reči
spajanje elizija	—	33 spajanja	428 → 395 reči

Restauracija interpunkcije

Mera	Prva verzija	Posle popravki
ukupno trajanje (3 min zapisa)	102 s	60 s
zahteva ka modelu	16	9
odbijenih odlomaka	8	1
vremena na odbačene odgovore	45%	10%
lažnih prelomâ na granicama	4	1
velikih slova usred rečenice	2	0

Preostali odlomak je odbijen s pravom: model je hteo da ukloni ponavljanje iz prepoznavanja, a to je izmena sadržaja. Nijedno popuštanje ga ne bi propustilo.

Provera na celoj datoteci: trinaest velikih slova usred rečenica, svih trinaest vlastita imena. Pravilo „vrati malo slovo samo ako je original bio mali" drži.

Prevod

Ocenjeno ručno na devet parova rečenica, sa referentnim prevodom napisanim unapred. Parovi su birani tako da postoji način da se pogreši: nazivi organizacija, nedovršene rečenice, dečji registar, birokratski pleonazam.

Ocena	Bez glosara	Sa glosarom

upotrebljivo kako jeste	3	6
treba mala ispravka	5	3
neupotrebljivo	1	0

Sve tri ozbiljne greške nestale su sa glosarom, a jedan par je postao identičan referentnom prevodu. Uzorak je mali i iz jednog konteksta; to je poznato ograničenje i skup se širi.

> **Jedna pretpostavka koju je merenje oborilo.** Prevodi su delovali „predugačko i preformalno", pa su po tome dodata pravila u upit. Merenje: odnos prema referentnom prevodu 1,06× — zanemarljivo — a nova pravila donela 0,6%. Utisak je poticao od dva para. Pravila su ostala jer ne škode, a ono o pravopisnoj varijanti je stvarno rešilo doslednost; predloženo tvrdo ograničenje po broju znakova je odbačeno, jer dužinu već drži prelamanje, koje zna profil i brzinu čitanja, dok bi model gađao broj naslepo.

Prevod postojećeg SRT-a

Jedan posao, 320 cue-ova, 25 minuta materijala, prevod na dva jezika:

Mera	francuski	engleski
cue-ova u izlazu	320	320
odstupanje tajminga od ulaza	0	0
rečenica sastavljenih iz 320 cue-ova	195	195
prekoračenja (profil iz originala)	59	35
od toga gore nego isti cue u originalu	59	33
rešeno skraćivanjem	38	23
rečenica vraćenih neprevedeno	5	3
prevod duži od originala	17%	6%

Neprevedene rečenice bile su napev pesme, isti u oba jezika — detekcija ih prijavljuje s pravom, jer ne razlikuje napev od propusta. Među njima je bila i jedna stvarna, rečenica koja je ostala na srpskom.

Obrazac koji se ponovio

Najmanje osam puta je objašnjenje kvara bilo uverljivo i pogrešno, a merenje je pokazalo drugo:

Simptom	Pretpostavljeni uzrok	Stvarni uzrok
nedostaje rep zapisa	filter tišine	filter halucinacija, preskok do kraja datoteke
jedna reč po rečenici	nema interpunkcije	izbor najveće pauze pri izjednačenju
restauracija se nije pokrenula		

	provera odgovora obarala odgovore	uslov nije ni okinuo — treći slučaj koji niko nije pokrivao
lažni prelomi rečenica	odlomak koji je odustao	svaka granica odlomka, jer model punktira kao celinu
razbijeni navodnici u izlazu	model vraća neuravnotežen tekst	rez između cue-ova pada između navodnika i reči
odbijeni odlomci pri prevodu	model prenumeriše od jedan	model dodaje svoje nabrajanje ispred našeg broja
prag detekcije ne menja rezultat	vrednost se gubi u kodu	merilo je išlo nad procesom koji drži stari kod u memoriji
oznaka nesigurnosti pali 80% rečenica	prag po reči je prestrog	pravilo „bar jedna loša reč" pojačava svaki udeo
izmišljen tekst preko džingla	model halucinira na muzici	glosar prethodnog posla, koji ulazi u svaki prozor
jedna reč sama u cue-u	nedostaje ravnomerna podela	izuzetak od kazne postavljen preširoko
obrada pala bez razloga	greška u zvuku ili modelu	zamena datoteke na Windowsu dok je ona otvorena drugde
skrol skače, brisanje ne radi	dve odvojene greške u interfejsu	jedno osvežavanje liste na tri sekunde
promena profila „ne radi"	kvar u prelamanju	radi, ali editor prikazuje rečenice a menja se titl
ime profila nestaje posle prelamanja	greška u odgovoru servera	merilo je čitalo stanje stranice pre zamene
glavna faza izgleda dobro pokrivena	hiljadu testova je dovoljno	pokrivenost te funkcije bila je 1% — broj testova nije merenje

> **Dva pogrešno postavljena kriterijuma.** Dva puta je merenje bilo tačno a odluka umalo pogrešna, jer je prag bio proizvoljan. Pravilo o registru menjalo je 15% rečenica i po kriterijumu „menja više od desetine" prolazilo — ali je čitanje dalo 11 boljih naspram 9 gorih, uz jednu pokvarenu reč, pa je odbačeno: broj promenjenih rečenica meri da li model primećuje pravilo, ne da li je prevod bolji. Apsolutna granica u zahtevu za skraćivanje nije dostigla cilj od 1,8×, ali je bila bolja od dotadašnje po sva tri merila, pa je uzeta. Pouka je ista: kriterijum se bira pre merenja, ali se proverava posle njega.

Otuda radni princip: svaki prag ispisuje veličinu po kojoj je odlučio, i nijedna hipoteza ne menja kod dok se ne izmeri.

Tri zamke koje nisu u pajplajnu nego oko njega

Poslednja trećina razvoja donela je nalaze bez veze sa zvukom i jezikom, od kojih bi svaki sam oborio alat u redovnoj upotrebi.

Zaštita nabrajanjem propušta ono što još nije napisano

Test koji je samo podigao aplikaciju pokrenuo je migraciju nad **stvarnim** poslovima, pre nego što je napravljena rezervna kopija. Prošlo je dobro samo zato što je migracija idempotentna i piše u dnevnik; sa greškom bi četrnaest poslova nestalo bez traga.

Zaštita koja je iz toga nastala nabrajala je ono što je stradalo: direktorijum poslova i datoteku podešavanja. Tri kruga kasnije **isti kvar na glosaru** — nov test je prepisao pravi `glossary/default.json`, a spasla ga je rezervna kopija koju glosar sam pravi.

> **Spisak fajlova koji su dosad stradali nije pravilo.** Zaštita je okrenuta naopako: svaki test dobija privremen koren projekta, a pisanje izvan njega je greška, ne izuzetak. Tada se ne pamti koji je fajl osetljiv — ne može se stići ni do jednog. Svaki nov kod koji radi pri pokretanju treba zamisliti kao nešto što će test pokrenuti.

Zamena datoteke na Windowsu pada dok je ona otvorena

Na Linuksu zamena radi i preko otvorenog opisnika; na Windowsu `os.replace` odbija ako je ciljna datoteka otvorena bilo gde. Posao je pao usred obrade i zavisni zadaci su preskočeni, iako sa zvukom i modelom nije bilo ničega.

Popravka je ponavljanje zamene posle 20, 40, 80, 160 i 320 milisekundi — datoteka je zauzeta na milisekunde — kroz jednu funkciju kojom idu **svi** upisi preko postojeće datoteke: zapis o poslu, rečenice, titlovi, podešavanja, glosar. Uz to je stranica projekta, koja je istu datoteku čitala tri puta po prikazu, svedena na jedno čitanje.

Ponavljanje smanjuje verovatnoću ali je ne uklanja, pa postoji i **dugme za ponavljanje koraka koji je pao**, sa svim što je zbog njega preskočeno. Bez njega je jedini izlaz ručno vraćanje statusa.

Gde ima nasumičnosti, jedan prolaz nije merenje

Izveštaj je iz jednog prolaza tvrdio da jedna kombinacija podešavanja daje 11 reči. Pet ponavljanja dalo je raspon 20 do 52. Taj broj nije bio merenje nego izvlačak.

Drugačiji obrazac od ostalih: ranije je hipoteza bila pogrešna, ovde tačna a uzorak nedovoljan. Granica je izmerena — od četiri kombinacije, tri su u pet ponavljanja dale prepis identičan do poslednjeg bajta; nasumičnost se javlja samo tamo gde model posle neuspelog dekodiranja podiže temperaturu.

Pravilo: gde postoji temperatura — filtriranje tišine sa spiskom očekivanih reči, i svaki poziv jezičkom modelu — ponavlja se i javlja raspon, ne jedan broj.

13. Faze razvoja

Razvoj je išao od jezgra ka ljusci, tako da svaka faza ostavlja upotrebljiv proizvod. Prva je namerno bila bez prevoda i bez interfejsa — da se izmeri koliko je prepoznavanje dobro na srpskom pre nego što se išta gradi oko njega.

Faza	Sadržaj	Stanje na kraju faze
1	obrada zvuka, prepoznavanje, segmentacija, prelamanje, transliteracija, titl — sve preko komandne linije	merljiv kvalitet prepoznavanja na stvarnom materijalu
2	prevod, provera odgovora, glosar, skup za ocenjivanje, izbor modela merenjem	titl na drugom jeziku, sa dokazanim izborom modela
3	interfejs: lista poslova, stranica posla, editor, obrada u pozadini, praćenje napretka	ceo tok bez komandne linije
4	jezičke normalizacije: ekavizacija, spajanje elizija, restauracija interpunkcije	upotrebljiv izlaz i za francuski i za srpski
5	upotrebljivost: pokretanje bez terminala, poništavanje, prečice, automatsko snimanje, podešavanja, čišćenje diska	alat za svakodnevni rad
6	prevod postojećeg SRT-a sa očuvanim tajmingom, profil iz ulaza, skraćivanje prekoračenja, tipografija po jeziku	drugi način upotrebe, nezavisan od zvuka
7	objašnjenja u interfejsu u dva sloja, stranica Kako ovo radi, uklanjanje starih napomena	alat upotrebljiv i nekome ko ga nije pravio
8	glosar po projektu, otkrivanje izmišljenih reči, nova podela profila sa migracijom, izostavljanje interpunkcije, veličina slova	prepis otporan na curenje tuđih termina
9	interfejs iz temelja: dva ulaza, baza projekata, prelom ispod rečenice, objašnjenja u prozorčiću, nijedna izmena ne čeka na dugme	alat koji se koristi bez objašnjavanja

Šesta faza nije bila planirana. Došla je iz konkretnog posla: titl na srpskom je već postojao, doteran u montaži, i trebalo ga je prevesti na francuski i engleski bez ijedne izmene vremena. Sve popravljeno posle nje — navodnici, numerisanje odlomaka, trajanje rečenice, detekcija neprevedenog, brisanje posla u toku — izašlo je na tom jednom poslu, u jedno popodne.

Stanje na dan ove verzije (v1.4): svih devet faza je završeno i aplikacija radi kao desktop alat sa ikonicom, bez vidljivog terminala. Oba toka — iz zvuka i iz gotovog titla — provereni su na stvarnim poslovima na srpskom, francuskom i engleskom, uključujući isporuku titla od 25 minuta na dva jezika. Hiljadu sto šezdeset testova prolazi, uz 87% pokrivenosti. Projekat je pod verzionisanjem, sa zaključanim verzijama zavisnosti.

Sledeći korak nije nova funkcija nego **period stvarne upotrebe**: najmanje mesec dana redovnog rada, uz beleženje ne onoga što je model pogrešio — to je poznato — nego onoga što u interfejsu usporava korekturu. Prioritete određuju ti nalazi, ne unapred sastavljen spisak želja.

Dosadašnje iskustvo to potvrđuje bez izuzetka: nijedan nalaz koji je oblikovao poslednje dve faze nije se mogao predvideti. Filter koji je gutao rep zapisa, sortiranje koje je pravilo jednorečne rečenice, navodnici koji su se prelivali između cue-ova, nabrajanje koje je model dodavao ispred rednog broja — sve je izašlo na prvom stvarnom poslu.

14. Rizici i otvorena pitanja za javnu verziju

Javna verzija — proizvod koji drugi koriste sami — odložena je za posle perioda stvarne upotrebe. Sledeća pitanja ostaju otvorena.

Hardverski zahtev je glavna prepreka. Kartica sa najmanje dvanaest gigabajta memorije je zahtev koji prosečan korisnik ne ispunjava, i on određuje sve ostale odluke o isporuci. Tri zaobilaženja, sa različitim posledicama:

Model isporuke	Za	Protiv
vlasnikova mašina kao server	ništa se ne menja u kodu; bez troška	mašina mora biti upaljena; dva posla ne staju u memoriju istovremeno
iznajmljena mašina sa karticom	uvek dostupno, nezavisno od vlasnika	trošak srazmeran vremenu rada, nesrazmeran obimu kratkih zapisa
zamena lokalnih modela spoljnim servisima	radi na najjeftinijem serveru; prevod verovatno bolji	zvuk napušta mašinu — direktno protivreči polaznom uslovu

Poverljivost materijala. Uslov da nijedan zapis ne napušta računar nije tehnički hir nego posledica sadržaja: izjave dece i korisnika socijalnih usluga. Treći model isporuke taj uslov ukida, pa nije tehnička opcija nego promena prirode proizvoda.

Zaštite pristupa nema. Aplikacija nema prijavu: ko dođe do adrese, može da otprema i briše. Za lokalnu upotrebu je to ispravno, za bilo šta mrežno preduslov pre prvog spoljnog korisnika.

Ime proizvoda. Naziv nije proveren na tržištu ni na žig. Pre bilo kakve javne distribucije potrebna je provera i, po potrebi, distinktivan pun naziv.

Skup za ocenjivanje je premali. Devet parova iz jednog konteksta, dva govornika — dovoljno da se izabere model, nedovoljno da se tvrdi bilo šta o kvalitetu prevoda uopšte. Proširenje na druge govornike, uslove snimanja i oblasti je preduslov za svaku tvrdnju upućenu nekome ko nije autor.

Pragovi su podešeni na malom uzorku. Prag gustine interpunkcije izveden je iz dva merenja i zato stoji kao rečnik po jeziku, a alat ispisuje veličinu po kojoj odlučuje da bi se merenja sakupljala. Isto važi za kazne u prelamanju.

Jezici i pisma. Srpski, engleski, francuski i nemački, sa tabelama funkcijskih reči za prva tri. Nov jezik traži tabelu; bez nje važe samo opšta pravila — prijavljeno, ali sa slabijim prelomima. Ekavizacija i transliteracija su svojstvene srpskom i nemaju analogiju drugde.

Prepoznavanje govornika. Namerno izostavljeno. Prošire li se poslovi na razgovore sa više učesnika, postaje potreba koja menja pajplajn i traži još jedan model u memoriji kartice.

Održavanje sprege sa karticom. Biblioteka za prepoznavanje i biblioteke kartice osetljive su na nadogradnje. Zaključane verzije su odlaganje, ne rešenje: svaka nadogradnja okruženja traži proveru.

Dokument je zaključen kao verzija 1.4 i služi kao polazna tačka za dalji razvoj i za procenu proširenja u javni proizvod. Prilog A omogućava da se alat napravi ponovo na drugoj mašini.

Prilog A — prompt za izgradnju alata

Ovaj prilog sadrži jedan tekst koji se nalepi u Claude Code (ili drugog agenta koji ume da piše datoteke i pokreće komande), u praznom projektnom folderu, kao prva poruka. Iz njega se ceo alat opisan u ovom dokumentu može napraviti ponovo.

Prompt nije sažetak dokumenta. Dokument objašnjava zašto su odluke donete, a prompt sadrži šta treba napraviti, u obliku koji agent može da izvrši: strukturu projekta, sheme datoteka, sve izmerene konstante sa razlogom, osam faza sa tačkama zastoja, redosled postavljanja sa svim spoljnim zavisnostima, i — ono što je najvredniji deo — dvadeset šest zamki koje su u ovom projektu otkrivene merenjem, svaka sa objašnjenjem kako se ispoljava i koliko je koštala. Svaka od njih je u izgradnji potrošila najmanje jedno popodne.

> **Dva razloga zašto se prompt isplati pročitati i ako se alat ne pravi ponovo.** Prvo, zamke su jedini deo ovog projekta koji se ne može izvesti iz dokumentacije biblioteka — svaka je pronađena na stvarnom poslu i nijedna nije bila ni na jednom spisku želja. Drugo, pravilo rada koje stoji na početku prompta („merenje pobeđuje pretpostavku", sa izričitim uputstvom agentu da prvo proveri pa onda popravlja) pokazalo se važnijim za ishod od bilo koje pojedinačne tehničke odluke: osam puta je uverljivo objašnjenje kvara bilo pogrešno.

Prompt je napisan za mašinu sa NVIDIA karticom od najmanje dvanaest gigabajta memorije, Pythonom 3.11 i lokalnom Ollamom. Na slabijoj konfiguraciji faze 1, 2 i 6 ne rade — to je ograničenje proizvoda, ne prompta, i opisano je u poglavlju 14. Uz ovaj dokument ide i datoteka `subtitis-prompt-sveobuhvatni.md` sa istim tekstom, pošto se iz PDF-a teže kopira.

Tekst prompta

```
Radimo na internoj desktop aplikaciji **Subtitis**. Ona pravi SRT titlove iz
audio i video zapisa i prevodi ih, i ume da prevede već gotov SRT bez diranja
tajminga. Sve se izvršava lokalno — nijedan zapis ne napušta mašinu, jer je
materijal poverljiv.

Radi **fazno**. Završi fazu, stani, javi mi izmerene rezultate i čekaj
potvrdu. Ne prelazi na sledeću fazu sam.

## Pravilo rada koje važi od prve do poslednje faze

**Merenje pobeđuje pretpostavku.** U izgradnji ovog alata je najmanje osam
puta uverljivo objašnjenje kvara bilo pogrešno, a pravi uzrok drugde. Zato:

- Kad ti kažem šta je uzrok nečega, **prvo proveri pa onda popravljaj.** Ako
  nalaz ne stoji, reci pre nego što uradiš.
- Svaku promenu koja utiče na kvalitet izlaza **izmeri pre i posle** i ispiši
  brojeve. Ne „bolje je" nego „155 → 173 reči, pokrivenost 55,9% → 83,8%".
- Pre nego što predložiš prag ili konstantu, ispiši veličinu na osnovu koje
  bi se odlučivalo — i ostavi je u redovnom ispisu, da se prag kasnije podesi
  na osnovu podataka a ne pogađanja.
- Kriterijum postavi **pre** merenja i formuliši ga tako da meri kvalitet, a
  ne da li je mehanizam primećen. („Menja više od desetine slučajeva" meri da
  model primećuje pravilo, ne da je rezultat bolji.)
- **Gde ima nasumičnosti, jedan prolaz nije merenje.** Jedan prolaz je dao 11
  reči, pet ponavljanja 20–52. To nije drugačija hipoteza nego nedovoljan uzorak.
```

  Svuda gde postoji temperatura — popuštanje posle neuspelog dekodiranja, svaki
  poziv jezičkom modelu — ponavljaj i javljaj raspon, ne jedan broj.
- Ne odbacuj popravku zato što nije dostigla proizvoljan cilj. Ako je bolja po
  sva tri merila, uzima se.

Minimum hardvera

Pročitaj ovo pre nego što počneš: ako mašina ne ispunjava prvi red tabele,
ništa od dalje opisanog ne radi, i bolje je da to kažeš odmah nego posle
preuzimanja petnaest gigabajta modela.

Deo	Minimum	Zašto
Grafička kartica	**NVIDIA, 12 GB VRAM** (razvijano na 16 GB)	prepoznavanje ~5 GB, prevod ~8 GB; nikad istovremeno, ali svaki mora da stane
Prostor na disku	**15 GB** za modele + **115 MB** po satu zapisa**	Whisper `large-v3` ~3 GB, `gemma3:12b` ~8 GB, ostalo biblioteke; radna kopija zvuka se briše po roku
Radna memorija	16 GB, SSD	procesor nije usko grlo, sve teško ide na karticu
Operativni sistem	Windows 10 ili noviji	na Linuksu radi isto, osim zaobilaženja koja su ovde označena kao windows-specifična

AMD kartica, Apple Silicon i rad samo na procesoru nisu podržani. Ako ti se
čini da bi neki od njih radio, **prvo izmeri**, pa javi — ne menjaj izbor
modela da bi stao u manju memoriju, jer je taj izbor donet merenjem kvaliteta
na srpskom.

Softver

- **Python 3.11** (ne 3.12 — `ctranslate2` ume da pravi problem)
- Ollama lokalno na `http://localhost:11434`
- `ffmpeg` u PATH — proveri na startu i javi jasnu grešku ako nije
- `venv`, sve zavisnosti u `requirements.txt`, bez Dockera i bez Poetry
- Radni jezici: srpski (najčešći), engleski, francuski, nemački

Podrazumevaj ovaj redosled postavljanja i napravi ga tako da prolazi od nule:

```
1. Python 3.11 (ne 3.12), uz „Add to PATH"
2. ffmpeg, uz ffmpeg.exe u PATH
3. NVIDIA drajver (CUDA 12.x dolazi uz njega; CUDA Toolkit nije potreban)
4. Ollama, pa `ollama pull gemma3:12b`
5. git clone, `python -m venv .venv`, aktivacija, `pip install -r requirements.txt`
6. `subtitis doctor`   — javlja šta od navedenog nedostaje
7. `subtitis serve`    — ili prečica na radnoj površini
```

Whisper model se preuzima sam pri prvom prepoznavanju, pa prvi posao traje
dodatnih nekoliko minuta; napiši to u ispis, inače izgleda kao da je stalo.

Napravi i komandu `doctor` koja proverava sve spoljne zavisnosti (ffmpeg,
Ollama, CUDA, modeli, prostor na disku) i ispisuje šta nedostaje, sa tačnom
komandom za svaku stavku — koristiću je prva. Ona je i jedini dokument o
postavljanju koji neće zastariti, jer se izvršava.

Osnovni princip arhitekture

**`words.json` je izvor istine. Sve ostalo je izvedeno i može se
regenerisati.**

Iz toga sledi:

- promena prelomnog profila → regeneriši SRT, **ne** pokrećeš ponovo
  prepoznavanje
- dodatni ciljni jezik → prevedi ponovo, **ne** pokrećeš ponovo prepoznavanje

- ručna korekcija → nikad se ne pregazi automatski

Modeli se nikad ne drže u VRAM-u istovremeno. Whisper large-v3 je ~5 GB, jezički model ~8 GB. Pajplajn je ionako sekvencijalan, pa posle svake faze oslobodi model: `keep_alive: 0` za Ollamu, `del` + `torch.cuda.empty_cache()` za Whisper.

Struktura projekta

```
subtitis/
  subtitis/
    __init__.py  __main__.py
    cli.py            # Typer CLI
    config.py         # subtitis.toml, port 8010
    bootstrap.py      # mora se izvršiti PRVI, vidi zamku o pythonw
    audio.py          # ffmpeg normalizacija
    asr.py            # faster-whisper
    segment.py        # reči -> rečenice
    punctuate.py      # uslovna restauracija interpunkcije
    ekavica.py        # kurirani rečnik, 4 sloja
    translit.py       # latinica <-> ćirilica
    linebreak.py      # prelamanje u cue-ove (DP sa kaznama)
    translate.py      # Ollama klijent + validacija
    srt.py            # čitanje i pisanje SRT-a
    fixedcues.py      # prevod SRT-a sa fiksnim tajmingom (faza 6)
    typography.py     # post-procesor po jeziku
    untranslated.py   # detekcija neprevedenog
    repeats.py        # detekcija ponavljanja
    models.py         # pydantic sheme
    pipeline.py       # orkestracija faza
    desktop.py        # pokretanje bez terminala
    web/
      app.py  db.py  worker.py
      templates/  static/
  profiles/ netflix.json tv.json web.json
  glossary/ default.json
  eval/ pairs.json
  scripts/ bench.py asr_probe.py vad_probe.py eval_translation.py
  tests/
  jobs/            # radni direktorijum, u .gitignore
  subtitis.bat
  subtitis.toml
  requirements.txt
```

Jedan posao na disku:

```
jobs/<job_id>/
  job.json          # status, parametri, istorija faza
  source.wav        # 16 kHz mono
  words.sr.json
  sentences.sr.json
  sentences.fr.json
  out/*.srt
  logs/job.log
```

Sheme

`words.json`:

```json
```

````
{"schema_version": 1, "job_id": "...", "source_file": "...",
 "duration": 180.44, "language": "fr", "script": "Latn",
 "asr": {"model": "faster-whisper/large-v3", "params": {},
         "detected_language": "fr", "detected_probability": 1.0},
 "words": [{"i": 0, "s": 0.00, "e": 0.34, "w": "Je", "p": 0.99}]}
```

`sentences.<lang>.json`:

```json
{"schema_version": 1, "language": "fr", "script": "Latn",
 "derived_from": "words.fr.json", "edited_by_human": false,
 "sentences": [{"id": 1, "s": 0.00, "e": 3.06, "text": "...",
                "words": [0, 7], "speaker": null,
                "flags": ["low_confidence"]}]}
```

---

# FAZA 1 — pajplajn preko komandne linije, bez prevoda i bez interfejsa

Cilj: izmeriti koliko je prepoznavanje dobro na srpskom **pre** nego što se išta gradi oko njega. Bez interfejsa, bez prevoda.

Redosled: `audio.py` → `asr.py` → `segment.py` → `linebreak.py` → `translit.py` → `srt.py`, i CLI komande `doctor`, `transcribe`, `build`.

## Prepoznavanje govora

`faster-whisper`, model `large-v3`, `device="cuda"`, `compute_type="float16"`. Izbor modela **fiksiraj u kodu** i ne izlaži ga na korisničkom ekranu — manji modeli su na srpskom osetno lošiji, a rizik da se izbor slučajno spusti bez objašnjenja veći je od koristi. Ostavi kao CLI opciju.

Parametri, svi kao imenovane konstante na vrhu modula:

```python
WORD_TIMESTAMPS = True            # osnovni zahtev, bez ovoga nema prelamanja
CONDITION_ON_PREVIOUS_TEXT = False  # glavna odbrana od petlji ponavljanja
HALLUCINATION_SILENCE_THRESHOLD = None   # NE MENJATI, vidi zamku ispod
COMPRESSION_RATIO_THRESHOLD = 2.4
LOG_PROB_THRESHOLD = -1.0
NO_SPEECH_THRESHOLD = 0.6
TEMPERATURE = [0.0, 0.2, 0.4, 0.6, 0.8, 1.0]
DEFAULT_VAD_PRESET = "isključeno"        # vidi merenje ispod
VAD_PRESETS = {"normalno": 0.35, "tih snimak": 0.20, "isključeno": None}
MAX_VAD_DISCARD_SHARE = 0.10
```

Jezik se zadaje **eksplicitno**. Automatska detekcija srpski redovno prepozna kao hrvatski i vrati ijekavicu. Ponudi i `auto`, ali prikaži šta je detektovao i sa kojom sigurnošću.

Ključevi glosara ulaze u `initial_prompt` — znatno poboljšava pogađanje imena.

Posle svakog prepoznavanja ispiši **pokrivenost** (udeo trajanja zapisa pokriven rečenicama) i nabroj praznine duže od 3 s sa tačnim vremenima. To je jedina zaštita od tihog gubitka sadržaja.

> **ZAMKA 1 — `hallucination_silence_threshold` guta rep zapisa.**
> Kada ta grana segment proglasi sumnjivim, u implementaciji izvrši
> `seek = content_frames` — preskok **do kraja datoteke** — i tiho obriše sav
> preostali sadržaj, bez ijednog reda u dnevniku. Izmereno: pokrivenost
````
````

> 55,9% → 83,8%, reči 155 → 173 čim je isključen. Ostavi ga na `None`, izloži
> kao izričitu opciju sa upozorenjem, i **napiši test koji pada ako ga neko
> vrati u podrazumevane parametre**, sa objašnjenjem u samom testu.

> **ZAMKA 2 — filter tišine (VAD) je podrazumevano isključen, suprotno
> očekivanju.** Tri prolaza istog tihog zapisa: prag 0,35 → 179 reči i 85,6%
> pokrivenosti; 0,20 → 180 i 87,9%; **isključeno → 189 i 88,9%**, uz osetno
> tačniji tekst. Na tihom zapisu filter seče delove govora koje model inače
> rekonstruiše iz konteksta. Odbrana od izmišljenog teksta ostaje na
> `condition_on_previous_text=False` i pragu kompresije.
> Izloži VAD kao **tri imenovana izbora**, ne kao broj — prag korisniku ne
> znači ništa dok ne pusti ceo prepis.
> Kad je filter uključen a odbacio bi više od desetine zvuka, predloži
> poređenje sa isključenim. Mera je **udeo odbačenog zvuka**, ne pokrivenost:
> najveća ikad izmerena pokrivenost je 88,9%, pa je kao prag beskorisna.

Segmentacija

Reči → rečenice po interpunkciji, uz zaštitu od skraćenica (`itd.`, `npr.`,
`dr.`, redni brojevi).

```python
MIN_SENTENCE_WORDS = 3
MIN_SENTENCE_DURATION = 1.0
MIN_DURATION_PER_WORD = 0.15
MAX_SENTENCE_DURATION = 15.0      # važi i za SRT režim iz faze 6
LOW_CONFIDENCE_THRESHOLD = 0.6
LOW_CONFIDENCE_SENTENCE_SHARE = 0.20
MIN_WORDS_FOR_SHARE_RULE = 5
```

Rečenica duža od `MAX_SENTENCE_DURATION` lomi se na najvećoj pauzi, a pri
izjednačenju na onoj **najbližoj sredini**.

> **ZAMKA 3 — `max()` nad listom torki pravi jednorečne rečenice.**
> Na francuskom zapisu je svaka reč postala zasebna rečenica (0,2–0,4 s).
> Objašnjenje koje se nameće — „nema interpunkcije pa nema na čemu lomiti" —
> je pogrešno. Pravi uzrok: `max()` nad listom parova `(pauza, indeks)`; kada
> su sve pauze jednake, a u tečnom govoru bez interpunkcije jesu, poređenje
> pada na drugi član i bira **najveći indeks**. Rez uvek na poslednjoj reči,
> pa rekurzija ljušti po jednu reč sa kraja do kraja zapisa. Eksplicitno
> zadaj ključ i tie-break ka sredini.

> **ZAMKA 4 — `low_confidence` na osnovu `any()` pali skoro sve.**
> Prvo rešenje je palilo oznaku ako **bilo koja** reč ima verovatnoću ispod
> praga: 41% rečenica na dobrom zvuku, 80% na lošem. Uzrok nije prag po reči
> nego `any()`. Pređi na **udeo** reči ispod praga (0,20), uz minimum reči da
> pravilo ne pali na kratkim rečenicama. Posle: 4% na dobrom, 40% na lošem
> zvuku. Obojene reči su pretežno kratke funkcijske reči na kojima je model
> nesiguran i kad ih tačno prepozna — prave greške su drugde.

Reči bez zvuka iza sebe

Postoji klasa izmišljenog teksta koju verovatnoća **ne vidi uopšte**. Na jednom
zapisu je poslednjih devet reči imalo trajanje tačno nula, sve na istom trenutku,
a verovatnoće `0.87`, `0.98`, `0.99` — model je siguran u ono što je izmislio.

```python
ZERO_DURATION_S = 0.02
MIN_RUN_FOR_FLAG = 2    # niz od dve ili više uzastopnih; interpunkcija se ne broji
```

Prijavi takav niz sa vremenima i tekstom, označi rečenicu oznakom **odvojenom** od
oznake nesigurnosti, i u editoru je oboji drugom bojom. To su dve različite

pojave: jedna znači da model nije siguran, druga da je siguran u nešto čega nema.

Pravilo mora da se primeni posle spajanja elizija, ne nad sirovim izlazom —
inače francusko `c'` `est` u ponovljenom `c'est c'est-à-dire` daje lažnu uzbunu i
navede te da podigneš prag.

Prelamanje u cue-ove

Ovo je srce alata i jedini netrivijalan deo. **Deterministički** — bez
jezičkog modela. Generiši kandidate za tačku preloma, dodeli kaznene poene,
izaberi kombinaciju sa najmanjim zbirom (dinamičko programiranje).

Vremena cue-a izvode se iz **stvarnih vremena prve i poslednje reči** u njemu.
Trajanje se ne deli srazmerno broju znakova — prava vremena postoje.

Situacija	Kazna
red duži od dozvoljenog	1000 / znak
razdvaja predlog od imenice (`u / kuću`)	300
razdvaja delove složenog glagola (`bi / došao`)	300
enklitika na kraju ili početku reda	300
razdvaja pridev od imenice	200
jedna reč sama u redu	400
brzina čitanja preko dozvoljene	100 / jedinica
prelom nije na granici klauze	50
prelom iza veznika	10
prelom posle zareza	0
neravnoteža redova	2 / znak
prekratak cue	20 / znak
svaki novi cue	20

```python
PENALTY_SHARE_DEVIATION = 4     # koristi se u fazi 6
PENALTY_PER_CUE = 20
MIN_ALIGNED_TOKEN_SHARE = 0.6
```

> **ZAMKA 5 — tabele funkcijskih reči moraju biti po jeziku.** Srpska
> enklitika ne sme ni da počne red, dok engleski i francuski pomoćni glagoli
> slobodno počinju red (`he / is going`). U istom skupu bi engleski dobio
> zabranu koja u tom jeziku ne postoji. Ako jezik nije u tabelama, primeni
> samo opšta pravila i **upiši upozorenje** — ne lomi tiho bilo gde.

> **ZAMKA 6 — francuska elizija nije spisak od četiri reči.** Rešenje je
> opštije: pravilo hvata svaki token koji se završava apostrofom, jer je
> elizija fonološka pojava.

Profili kao JSON fajlovi:

Profil	oblik	brzina (CPS)	trajanje cue-a	izlaz
tv	2 reda × 42 znaka	20	0,83 – 7,0 s	kako jeste
web	1 red, 10–20 znakova	20	0,50 – 4,0 s	kako jeste
digital	isto kao `web`	20	0,50 – 4,0 s	VELIKA SLOVA, bez interpunkcije

Ne pravi tri varijante istog (42 / 37 / 47 znakova u dva reda) — izbor među njima
ne nosi odluku. Razlika mora biti u **obliku**.

Za jednoredni profil isključi tri kazne koje tamo mere nešto čega nema: jedna reč
sama u redu, neravnoteža dva reda, prekratak cue po znakovima. Kazna za enklitiku
ostaje i tamo je vidljivija nego inače, jer se dva dela sintagme pojavljuju u
različitim trenucima. Umesto isključenih uvedi **donju granicu dužine reda** kao
meku kaznu (30 po znaku ispod 10), sa izuzetkom **samo kad je cela rečenica kraća
od granice** — ne kad je kratak ostatak posle reza, inače svaki poslednji komad

rečenice prolazi bez kazne i dobijaš natpis od tri znaka.

Promena profila ne pokreće nikakvu ponovnu obradu — samo regeneriše SRT iz sačuvanih rečenica. Prikaži kojim je profilom napravljen postojeći fajl.

Transliteracija

Smer ćirilica → latinica je trivijalna zamena. Obrnuti smer je zamka.

> **ZAMKA 7 — digrafi `lj`, `nj`, `dž` nisu uvek digrafi.**
> `nadživeti` → `надживети` (ne `нaдивети`), `injekcija` → `инјекција`,
> `konjugacija` → `конјугација`, `podžanr` → `поџанр`, `Tanjug` → `Танјуг`.
> Zato je transliteracija deterministična funkcija sa listom izuzetaka u kodu
> (prefiksi `nad-`, `pod-`, `od-`, `pred-`, internacionalizmi sa `nj`/`inj`),
> a **ne biblioteka**. Svaki gornji primer dobija svoj test.
> Ovaj korak nikada ne izvršava jezički model — mora biti stopostotno
> predvidiv.

Format izlaza

Standardni SRT: redni broj, vremenski opseg, tekst, prazan red. Kodiranje **UTF-8 bez BOM-a**, prelomi redova **CRLF**. Obe stavke su izvor tihih problema u plejerima ako se pogreše. Imenovanje po oznaci jezika, sa pismom gde je relevantno; profil **ne** ulazi u ime fajla.

Na kraju faze 1 — stani

Pokreni prepoznavanje na stvarnom zapisu i javi mi: broj reči, broj rečenica, pokrivenost, praznine preko 3 s, odnos prema stvarnom vremenu, i izgled prvih dvadeset cue-ova. Čekam da pročitam pre nego što idemo dalje.

FAZA 2 — prevod

Ollama, podrazumevani model **`gemma3:12b`**. Izbor je donet merenjem na skupu od devet parova rečenica iz stvarnog materijala sa ručno napisanim referentnim prevodom; ocenjivano ručno u tri stepena, jer automatske mere na toliko malom uzorku ne znače ništa. `gemma3:12b` (7,8 GB, 37 tok/s, 1,03× dužine reference) pobedio je `qwen3:14b` (9,7 GB, 35 tok/s, 1,06×) na kvalitetu, brzini i memoriji. Napravi `eval/pairs.json` i skript za ocenjivanje da se izbor može ponoviti.

```python
num_ctx = 8192
temperature = 0.2
top_p = 0.9
repeat_penalty = 1.0
think = False
CHUNK_SIZE = 9        # rečenica po zahtevu
```

Tri tehnička uslova — bez njih sistem tiho ne radi

1. **Isključeno rezonovanje.** Model podrazumevano „razmišlja" pre odgovora, što za prevod znači sedmostruko sporiju obradu bez koristi. Proveri **dvostruko**: novije verzije vraćaju rezonovanje u zasebnom polju, ne u oznakama.
2. **Izričita veličina konteksta.** Podrazumevanih 4096 tokena servis **tiho odseca**, bez greške i bez traga. Posle prvog poziva pročitaj vrednost nazad iz servisa i uporedi.
3. **Provera nepoznatih polja.** Servis tiho prihvata izmišljena polja — greška u imenu opcije ne ostavlja trag. Čitaj stvarno primenjene vrednosti nazad, ne pretpostavljaj ih.

Prevodi se rečenica, ne cue

Prevođenje pojedinačnih cue-ova je najčešća greška u ovakvim sistemima: cue
je proizvoljan isečak rečenice i izolovano gubi rod, padež i vezu sa
kontekstom. Prevodi **rečenice, sa dve rečenice konteksta sa svake strane**
koje se šalju ali ne prevode. Prelamanje se posle radi **ponovo**, nad ciljnim
jezikom i njegovim pravilima.

Prevod je zasebna faza koju pokreće izričit klik, **nikad automatski** —
prevođenje neispravljenog teksta prevodi i greške, pa se onda ispravljaju dve
datoteke umesto jedne.

Zaštita od pomeranja

Najozbiljniji kvar nije loš prevod nego **pomeren prevod**: pošalješ deset
numerisanih rečenica, model vrati devet, ceo ostatak fajla se pomeri za jedan
red — a tekst izgleda savršeno. Zato traži numerisan izlaz u tačnom formatu i
proveri broj programski. Neuspeh → prepolovi odlomak → dve rečenice → jedna
po jedna. Posle dva neuspeha na pojedinačnoj rečenici upiši original sa
oznakom i idi dalje. Jedna rečenica nikad ne obara ceo posao.

Dopuna iz merenja: ako se ista greška ponovi u manjem odlomku kao u većem,
prekini polovljenje odmah — očigledno ne pomaže.

> **ZAMKA 20 — glosar curi u prepis tamo gde nema govora.**
> Ključevi glosara idu u `initial_prompt`, ali da bi preživeli ceo zapis moraju i u
> `hotwords`, koji ulazi u **svaki** prozor od 30 s. Gde model nema šta da čuje —
> muzika, džingl, špica — vraća baš te reči. Mereno na zapisu od 32 s sa džinglom:
> sa glosarom 77 reči i pet termina preko džingla doslovno
> (`Otvorena vrata, letnja radionica, OKC, Divčibare, Srbija`), sa praznim
> glosarom 66 reči i nijedan termin.
> **Glosar mora biti vezan za posao, ne globalan**, sa kopijom pri otvaranju i
> praznim glosarom kao ravnopravnim izborom. Globalan glosar znači da materijal
> jedne organizacije curi u snimke druge.

> **ZAMKA 21 — filter tišine i glosar zajedno daju nasumičan prepis.**
> Četiri kombinacije, svaka pet puta: bez glosara prepis je ponovljiv i sa filterom
> i bez njega; **sa oba uključena izlazi 20–52 reči, svaki put drugačije.** Filter
> seče zapis u kratke odsečke, u svaki ulazi glosar, i model na njima odustaje pa
> vraća prompt. Filter sam po sebi radi uredno. Ne meri ih odvojeno — interakcija
> se vidi samo u tabeli 2×2.

> **ZAMKA 8 — brojevi koje model vidi moraju počinjati od 1.**
> Dok su se odlomku šiljali stvarni identifikatori rečenica, model je ispred
> njih dodavao **svoje** nabrajanje: `1. 28|And then we packed the tents…`. Provera nije
> prepoznavala cifru i odbacivala ceo odlomak — 14 od 16 odbijanja na jednom
> poslu. Šalji lokalne brojeve `1..n` i drži mapiranje u kodu. Izmereno:
> **16 odbijenih odlomaka → 0, zahteva 54 → 22, vreme 326 → 181 s.**

Kada prevod nije prevod

Provera broja linija ne hvata slučaj u kom model vrati **izvorni tekst** pod
ispravnim rednim brojem — a u gotovom titlu to izgleda kao da je sve prošlo.
Zato posle prevoda radi zasebna provera: rečenica je sumnjiva ako sadrži slova
kojih u ciljnom jeziku nema (`ć đ š ž č` za francuski) ili je po rečima 80%
ista kao original. **Vlastita imena izuzmi** — bez tog izuzetka `Jelena Đurđević`
i nazivi organizacija imaju veći udeo takvih slova od pravih promašaja.
Izveštaj navodi **broj cue-ova**, ne rečenica: jedna neprevedena rečenica ume
da pokriva deset cue-ova.

Glosar

Tabela termina po smeru prevoda (`sr->en`, `sr->fr`). Koristi se na dva mesta:

```
ključevi u `initial_prompt` za prepoznavanje, celi parovi u prevodni upit.

Izmereno: bez glosara `Radionica otvorenih vrata` → „Open Doors Workshop",
`animator` → „animator", `sporazumevati se` → „to reach an agreement" (pravno
značenje umesto svakodnevnog); sa glosarom sva tri tačno, i greška se vraća
čim se unos ukloni.

U glosar se upisuju i termini koje **ne treba menjati** (`"Đurđević": "Đurđević"`),
da ih model ne transliteruje ili „popravi".

## Pivot preko trećeg jezika

Za parove sa slabom direktnom spregom (srpski → francuski) implementiraj i put
preko engleskog, kao podešavanje. Ne odlučuj unapred — oba puta postoje, a
merenje odlučuje. Glosar za drugi skok izvedi iz postojećih smerova; ako
ostane prazan, upiši upozorenje.

## Na kraju faze 2 — stani

Javi mi rezultat ocenjivanja nad `eval/pairs.json` za oba modela i prevod
istog zapisa sa glosarom i bez njega.

---

# FAZA 3 — veb interfejs

FastAPI + SQLite + Jinja2 + HTMX + SSE. **Bez Reacta i bez koraka izgradnje** —
za alat koji koristi jedan čovek lanac alata za izgradnju je veći teret od
koristi.

Ekrani: lista poslova i nov posao; stranica posla sa fazama i napretkom;
editor rečenica; podešavanja i glosar.

Worker je **nit unutar servera**, ne zaseban proces — korisnik ne treba da zna
da postoje dva procesa. Zadrži zasebnu komandu za razvoj (`--no-worker` da se
nit isključi). Nit ne sme da zadržava gašenje: petlja čeka na **događaj**, ne
na istek vremena, i najviše dve sekunde pri gašenju.

Indikator „obrada aktivna" u zaglavlju hrani otkucaj iz **zasebne** niti na 5
sekundi. Da ga kuca glavna petlja, indikator bi pocrveneo usred svakog dužeg
prepoznavanja. Prelaz u crveno posle 20 s bez otkucaja.

SSE za napredak. U editoru: bojenje po sigurnosti, poništavanje, automatsko
snimanje, isečak zvuka po rečenici (dugme ▶), prečice.

## Funkcionalna pravila

- **Izvedeni fajlovi se uvek mogu regenerisati** — promena profila ili pisma
  ne pokreće prepoznavanje ni prevod.
- **Ručna ispravka se nikad ne pregazi.** Fajl sa oznakom ljudske izmene ne
  prepisuje se automatski; ponovno prepoznavanje vraća odbijanje i traži
  izričitu potvrdu, uz rezervnu kopiju. Provera se izvodi **posle**
  prepoznavanja a ne pre — radije jedan uzaludan prolaz nego pregažene
  ispravke.
- **Ispravljen tekst zadržava prava vremena.** Poravnaj izmenjeni tekst sa
  originalnim tokenima; nepromenjena mesta zadržavaju stvarna vremena,
  interpoliraju se samo dodati tokeni. Ako udeo poravnatih tokena padne ispod
  `MIN_ALIGNED_TOKEN_SHARE`, označi degradirano poravnanje i upiši upozorenje
  — tiho loše poravnanje se otkriva tek u plejeru.
- **Neuspeh prekida zavisne zadatke** — ne izvršavaj prelamanje nad
  nepostojećim rečenicama i ne prijavljuj „gotovo". Preskočeni zadaci se vide
  sa razlogom.
- **Prazan rezultat je greška**, ne uspeh sa praznim titlom. Jedan prazan
  zapis je prošao ceo tok i proizveo titl od nula bajtova označen kao gotov.
```

- **Posao se može obrisati i dok radi.** Radna kopija zvuka ne može se
  obrisati dok posao ima zadatak; sam posao može — brisanje otkazuje zadatak,
  a obrada staje na prvoj prirodnoj tački, između delova posla, nikad usred
  poziva modelu. Prekid **ne sme** biti ista klasa greške kao ostale greške
  pajplajna: te se na nekim mestima hvataju da bi se nastavilo, pa bi prekid
  bio progutan. Posle prekida worker ne pada, nego prelazi na sledeći zadatak
  i **još jednom** briše direktorijum — zadatak ume da upiše dnevnik posle
  brisanja, a na Windowsu se fajl koji je držao otvorenim ne može obrisati dok
  ga ne pusti.
- **Pisma i jezici se proveravaju na serveru.** Izbor pisma je dostupan samo
  kad je ciljni jezik dvopismen; zahtev za ćirilicom nad jezikom koji je nema
  odbija se sa jasnom porukom u interfejsu, ne sistemskom greškom.

> **ZAMKA 9 — kodni raspored konzole ruši mrežne zahteve.** Dnevnik je išao
> direktno na standardni izlaz, a Windows konzola koristi cp1252 koji ne
> poznaje `ć š đ ž` — dakle skoro svaku poruku na srpskom. Svaki takav ispis
> rušio je **ceo HTTP zahtev**, usred snimanja korekture, sa porukom koja nema
> veze sa uzrokom. Pravilo: **fajl dnevnika je uvek u punom UTF-8; ispis u
> konzolu pada na zamenu znakova, pa na tiho odustajanje.**

> **ZAMKA 22 — na Windowsu zamena datoteke pada dok je ona otvorena.**
> Za razliku od Linuksa, `os.replace` odbija ako je ciljna datoteka otvorena bilo
> gde — i obara ceo posao usred obrade, sa preskočenim zavisnim zadacima. Napravi
> jednu funkciju koja ponavlja zamenu posle 20, 40, 80, 160 i 320 ms, i **pusti sve
> upise preko postojeće datoteke kroz nju**: zapis o poslu, rečenice, titlove,
> podešavanja, glosar. Uz to proveri da nijedan prikaz ne čita istu datoteku više
> puta. Pošto ponavljanje smanjuje verovatnoću ali je ne uklanja, dodaj i **dugme
> za ponavljanje koraka koji je pao**, zajedno sa svim što je zbog njega
> preskočeno.

> **ZAMKA 23 — osvežavanje liste na nekoliko sekundi kvari tri stvari odjednom.**
> Zamena celog bloka vraća skrol na vrh dok korisnik čita, guta brisanje (forma
> zamenjena usred potvrde, pa projekat ostaje) i drži stalan pritisak na datoteke.
> Osvežavaj **samo kad bar jedan projekat ima zadatak**, i tada menjaj samo oznake
> statusa, ne ceo blok. Lista koja se sama menja dok ništa ne radi je laž o stanju.

> **ZAMKA 10 — Python ne pretovaruje module.** Pri merenju pragova je
> izgledalo da nova vrednost „ne stiže do obrade". Uzrok nije bio u
> prosleđivanju nego u tome što je worker držao stari modul u memoriji.
> **Restartuj proces pre svakog merenja.**

- Svaki korak beleženja greške zaštiti **zasebno** — nađeno je da i sam upis
  greške može baciti izuzetak i oboriti celu petlju obrade.
- Nalaženje spoljnih alata: podešavanje → PATH sistema → poznate lokacije
  instalacije. Razvojno okruženje drži kopiju PATH-a od trenutka pokretanja i
  ne vidi kasnije instalacije, pa je `ffmpeg` bio „nedostupan" iako je bio
  uredno instaliran.

Na kraju faze 3 — stani

FAZA 4 — jezičke normalizacije

Tri normalizacije nad `words.json`, **pre** segmentacije, tako da sve što
sledi radi sa čistim ulazom. Svaka beleži broj izmena i svaku pojedinačnu
izmenu u dnevnik.

Pismo

Model za srpski vraća čas ćirilicu, čas latinicu, ponekad pomešano unutar
istog fajla. Svedi izlaz odmah na latinicu i radi interno isključivo njome —
tokenizacija je bolja, a modeli za prevod su na latinici pouzdaniji. Ćirilica
se dobija transliteracijom na samom kraju.

Ekavizacija

> **ZAMKA 11 — regularni izraz za ijekavicu uništava reči.** Pravilo
> „ije/je → e" bi pokvarilo `jesen`, `jedan`, `jezik`, `prijem`, `sjaj`.
> Rešenje je **kurirani rečnik u četiri sloja**, gde se sloj zaštite proverava
> prvi:
>
> | Sloj | Značenje | Primer |
> |---|---|---|
> | zaštićeno | nikad se ne dira | `jesen`, `jezik`, `prijem`, `Mjanmar` |
> | tačan oblik | cela reč | `prije` → `pre` |
> | prefiks | reč počinje osnovom | `djec` → `dec` |
> | bilo gde | osnova unutar reči | `vidje` → `vide`, hvata i `predvidjeti` |
>
> Pri učitavanju modula proveri tabele na **međusobne sudare** — provera je
> već uhvatila slučaj gde bi zaštićena imenica `želja` blokirala glagol
> `željeti`.

Spajanje elizija

Na francuskom model vraća razdvojene oblike: `j 'aimerais`, `d 'autres`,
`c 'est`, `aujourd 'hui`. Posledica: prelamanje vidi `j` i `'aimerais` kao dve
reči, pravilo o eliziji nikad ne okine, i cue počinje sa `'espère`.

Pokrij kratke osnove po pravilu i duže po spisku (`qu`, `jusqu`, `lorsqu`,
`aujourd`, `puisqu`, `quoiqu`, `quelqu`, `presqu`). Nova reč uzima početak
prve i kraj druge, a **manju od dve verovatnoća** — da spajanje ne sakrije
nesigurnost koju editor treba da oboji. Izmereno: 33 spajanja, 428 → 395
reči, nijedan token više ne počinje apostrofom.

Restauracija interpunkcije

Zarezi su glavni signal za tačku preloma unutar rečenice. Tekst bez njih daje
loše prelome bez obzira koliko je algoritam dobar. Model za prepoznavanje
punktira nepouzdano — na jednom zapisu je uredno postavio znake u prvih pet
rečenica pa prestao do kraja.

Uslovni korak šalje tekst jezičkom modelu sa zahtevom da vrati **identičan
niz reči**, dodajući samo interpunkciju i velika slova.

Kapija

```python
PUNCTUATION_DENSITY_THRESHOLD = {"default": 4.0}   # znakova kraja / 100 reči
COMMA_DENSITY_THRESHOLD = {"default": 8.0}         # zareza / 100 reči
MIN_WORDS_FOR_DIAGNOSIS = 25
```

Pokreni restauraciju samo ako je **i** gustina znakova kraja ispod praga **i**
gustina zareza ispod svog praga.

> **ZAMKA 12 — kapija samo po znacima kraja lažno okida.** Prvo rešenje je
> odlučivalo samo po znacima kraja. Jedan zapis je imao 3,4 znaka kraja na sto
> reči, ali **17,6 zareza** — sasvim dovoljno za prelamanje. Restauracija je
> svejedno pokrenuta: 61 s, od toga 33 bačene, pet od osam odlomaka odbijeno,
> i dva sumnjiva ustupka (`curic → curi` i `curic → curici` u istom prolazu).
> Zarezi su ono što prelamanje stvarno koristi, pa oni ulaze u odluku.

Odluka po **gustini**, ne po prosečnoj dužini rečenice: „Dobar dan. Hvala."
ima prosek 1,5 reči po rečenici i savršenu interpunkciju.

Pragove izloži kao **rečnik po jeziku** — francuski i engleski imaju kraće
rečenice od srpskog i prirodno višu gustinu, a sa dva merenja se ne može

izvesti jedan broj koji važi svuda. Ispiši gustinu posle **svakog**
prepoznavanja, bez obzira da li kapija okine, **i koja je od dve odlučila**.

Validacija odgovora

Poredi odgovor sa originalom reč po reč, bez interpunkcije i bez razlike u
veličini slova. Izmena sadržaja obara **ceo** odgovor. Dve klase odstupanja
dozvoli, jer su pravopisne a ne značenjske:

```python
ALLOW_WORD_SPLITS = True        # ya -> y a; spojeni delovi moraju dati original
ALLOW_INFLECTION_CHANGES = True # prefiks >= 3 znaka, razlika <= 2 znaka
ALLOW_DIACRITIC_CHANGES = False # tres -> très ostaje zabranjeno
```

Svaki dozvoljeni ustupak beleži se sa konkretnim rečima.

Povlačenje na poslednji znak

> **ZAMKA 13 — model punktira svaki odlomak kao zaokruženu celinu.** Zatvori
> ga tačkom, a sledeći počne velikim slovom — posledica su lažni prelomi
> rečenica na granicama odlomaka: `...avant la pluie.` / `Nous avons rangé le matériel...`
> gde je original bio jedna rečenica. Moja prva hipoteza („odlomak koji je
> odustao") bila je pogrešna.
>
> Rešenje je deterministično i ne traži poverenje u model: posle svakog
> odlomka nađi **poslednji rečenični znak koji nije na samom kraju**, prihvati
> izlaz do tog mesta, a rep vrati u sledeći poziv gde ima pravi nastavak. Uz
> to vrati veliko slovo prve reči na malo — ali samo ako je original bio mali,
> da vlastita imena ostanu netaknuta. Zaštita: ako bi rep bio veći od polovine
> odlomka (`MAX_RETREAT_SHARE = 0.5`), prihvati izlaz kakav jeste uz
> upozorenje, da se izbegne beskonačno vraćanje.
>
> Izmereno pre/posle: 102 s → 60 s, 8 → 1 odbijen odlomak, 45% → 10% bačenog
> vremena, tri od četiri lažna preloma nestala. Četvrti je ostao tačno tamo
> gde je zaštita presekla povlačenje — cena zaštite je vidljiva i prihvaćena.

```python
MIN_CHUNK_WORDS = 20
```

Na kraju faze 4 — stani

FAZA 5 — upotrebljivost i pokretanje bez terminala

`subtitis.bat` u korenu koji diže server i otvara pregledač. Dvoklik i radi.
Ikonica na radnoj površini preko `pythonw`.

Ikonicu crtaj skriptom, i boje čitaj iz `app.css` — ne prepisuj ih.
Skript nacrta `.ico` sa svim veličinama koje Windows traži (16 do 256 px,
svaka crtana za svoju veličinu, jer smanjivanje 256 → 16 zamuti tanak okvir).
Boje uzima iz `:root` promenljivih teme; ako neka nedostaje, **pada sa jasnom
porukom** umesto da se vrati na rezervnu vrednost. Prepisana boja se raziđe sa
temom pri prvoj promeni i niko to ne primeti, jer ikonica izgleda uredno sama
za sebe. Istu datoteku serviraj i kao ikonicu u kartici pregledača, na
`/favicon.ico` i kroz `<link rel="icon">` sa verzijom u putanji — bez toga
pregledač dobija 404 i prikazuje svoju podrazumevanu sliku, što takođe niko
ne prijavljuje.

> **ZAMKA 14 — `pythonw` nema standardni izlaz, i puca pre prvog sopstvenog
> reda koda.** U režimu bez terminala `sys.stdout` je `None`, a
> `uvicorn.Config` zove `sys.stdout.isatty()` — izuzetak iz tuđeg koda, pre

```
> nego što se izvrši ijedan tvoj red. Rešenje: `bootstrap.py` koji se
> izvršava **prvi**, podmeće izlaz u fajl i upisuje svaki neuhvaćen izuzetak
> sa punim tragom. Bez toga prečica na radnoj površini ne radi, a nigde se ne
> vidi zašto.

> **ZAMKA 15 — provera „jedna instanca" ne sme gledati samo otvoren port.**
> Port 8000 je bila zauzela tuđa aplikacija, pa je Subtitis mislio da je već
> pokrenut i otvarao pregledač na tuđem sajtu. Dodaj `/api/identity` i proveri
> **identitet**, ne otvoren port. Podrazumevani port pomeri na 8010.

Čišćenje diska:

| Mera | Vrednost |
|---|---|
| ograničenje otpremanja | 2 GB (nedovršeno se briše) |
| rok brisanja radne kopije zvuka | 7 dana |
| čišćenje | pri pokretanju **i** na svakih 6 sati |

Čišćenje mora biti periodično a ne samo pri pokretanju — aplikacija ume da
radi nedeljama bez restarta, pa bi „pri pokretanju" značilo nikad. Prikaži
zauzeće po poslu i ukupno. Zasebno dugme za brisanje samo radne kopije zvuka
nije potrebno — rok ga ionako briše, a ceo posao se briše jednim dugmetom.

Rezervne kopije pre svake izmene rečenica, sa vremenskom oznakom **i
brojačem** — puna sekunda je preniska rezolucija, dva snimanja u istoj
sekundi su davala isto ime i drugo je tiho pregazilo prvo. Sortiraj po
vremenu i brojaču, ne po imenu.

Tri sloja zaštite u editoru: poništavanje u toku rada, povratak na poslednje
snimljeno stanje, lista svih ranijih verzija sa vremenom i brojem rečenica.
Povratak prvo snima tekuće stanje, pa i on može da se poništi.

`.gitignore` napiši **bez inline komentara** — `import/ # komentar` ne radi i
audio je ušao u repo. Izuzmi `jobs/`, `import/`, `venv/`, modele. Zaključaj
verzije zavisnosti (`requirements.lock.txt`) u trenutku kada je kombinacija
potvrđeno radila: sprega između `faster-whisper` i CUDA biblioteka je osetljiva
na nadogradnje.

## Na kraju faze 5 — stani

---

# FAZA 6 — prevod postojećeg SRT-a sa očuvanim tajmingom

Drugi način upotrebe: umesto zvuka, ulaz je gotov titl. Povod je konkretan —
titl na jeziku originala često nastane izvan alata, ručno doteran u montaži,
sa vremenima podešenim uz sliku. Kada za taj titl zatreba prevod, sve što je u
njemu urađeno mora ostati netaknuto.

**Tvrda garancija: broj cue-ova i sva vremena u izlazu identični su ulazu.**
Ne menja se ništa osim teksta. Provera se izvodi **pre upisa** — ako se
tajming razlikuje, titl se ne zapisuje. Napiši i test koji poredi ulazni i
izlazni fajl red po red.

## Tri koraka

1. **Sastavljanje.** Rečenice se sklapaju iz cue-ova po interpunkciji.
   Rečenica se često prostire kroz više cue-ova, a jedan cue ume da sadrži
   kraj jedne i početak druge.
2. **Prevod.** Prevode se cele rečenice, sa kontekstom, kao i inače.
3. **Raspoređivanje nazad.** Prevedena rečenica se deli na onoliko delova
   koliko je original imao cue-ova, sa istim udelom znakova po delu.

Tačke deljenja bira **isto skorovanje koje radi prelamanje** — iste kazne za
```

funkcijske reči, iste tabele po jeziku. Razlika je samo u tome što su granice zadate a ne predmet optimizacije, pa dodaj kaznu za odstupanje od ciljnog udela (`PENALTY_SHARE_DEVIATION = 4`).

`MAX_SENTENCE_DURATION = 15.0` važi i ovde: jedan nedosledno interpunktiran ulaz je dao rečenicu od 15,96 s koja je sadržala tri odvojene misli. Pauze između cue-ova kao dopunski signal granice su **merene i odbačene** (pragovi 1,0 / 1,5 / 2,0 s): preko onoga što trajanje već hvata dodavale su tačno jedan presek, i taj je bio pogrešan. Mehanizam ostavi u kodu, isključen, sa upisanim merenjem (`SRT_MAX_GAP = None`).

Profil se izvlači iz ulaza, ne nameće se

> **ZAMKA 16 — merenje prevoda standardnim profilom daje besmislene brojke.**
> Prva verzija je prijavljivala 47 prekoračenja od 204 cue-a. Merenje na samom
> ulazu je pokazalo zašto: ručno doteran original ima najduži red 51 znak (26
> redova od 219 preko 42) i najveći CPS 27,9 (18 cue-ova od 204 preko 20).
> Autorov sopstveni titl, koji je prihvatio i isporučio, probija standardni
> profil na 44 mesta. Mereno tim profilom, prevod se poredi sa normom koju ni
> original ne poštuje.
>
> Uvedi **profil izveden iz ulaznog fajla** kao podrazumevani za ovaj režim.
> Vrednosti sa **95. percentila, ne sa maksimuma** — maksimum pretvara jedan
> izuzetan red u normu:
>
> | Profil | redova preko 42 zn. | prekoračenja | od toga gore od originala |
> |---|---|---|---|
> | original (ulaz) | 12% | — | — |
> | netflix | 0% | 47 | 44 |
> | maksimum (51 / 27,9) | 17% | 8 | 8 |
> | **95. percentil (47 / 21,4)** | **11%** | **35** | **33** |

Izveštaj o prekoračenjima meri ono što stvarno treba: **koliko je cue-ova teže za čitanje nego isti cue u originalu.** Uz svaki prijavljeni cue ispiši i vrednost koju je imao pre prevoda.

Na dva posla izmereno isto: **sva prekoračenja su brzina čitanja, nijedno dužina reda.** To nije slučajnost nego posledica postavke — vremena su fiksna, a ciljni jezik je duži od srpskog za 15 do 20 procenata. Prelamanje to ne može rešiti; ono samo raspoređuje tekst, ne skraćuje ga.

Skraćivanje prekoračenja

Drugi prolaz kroz model, koji pokreće **dugme i nikad automatski**. Šalju se samo rečenice čiji su cue-ovi gori od originala, uz izvorni tekst i granicu u znakovima. Predlog se prihvata samo ako je stvarno kraći, ako je brzina čitanja pala i ako nije izgubio termin iz glosara.

> **ZAMKA 17 — model seče više nego što se traži, i tu se gubi značenje.**
> Za potrebnih 1–2 znaka ume da skrati i 40. Tri formulacije zahteva su
> merene: „kraće za najmanje N" (2,73× traženog), opseg (2,36×), **apsolutna
> granica „najviše X znakova" (2,15×, uzeta)**. Čitanjem svih prihvaćenih
> predloga: oko tri četvrtine je čisto (izbačene poštapalice i ponavljanja),
> oko desetine menja značenje, ostatak gubi sadržaj — na primer šalu koja je
> bila poenta rečenice. Zato **ništa se ne upisuje bez pregleda**, a predlozi
> skraćeni znatno više od traženog stoje bez kvačice i moraju se uključiti
> ručno.

Izmereno: francuski 47 pokušano / 36 prihvaćeno / 38 od 59 izašlo iz prekoračenja / prosečno 27,6 znakova (26%); engleski 29 / 24 / 23 od 33 / 22,6 znakova (29%).

Tipografija po jeziku

Izlaz prolazi kroz post-procesor specifičan za ciljni jezik. Francuski traži nerazlomljivi razmak pre `? ! : ;` i unutar `« »` — bez toga titl izgleda pogrešno svakom francuskom čitaocu, kao što bi nama izgledalo `reč ,`. Razmaci se računaju u dužinu reda **pre** prelamanja, da ne probiju profil naknadno.

> **ZAMKA 18 — navodnici se raspadaju pri raspoređivanju, ne u modelu.**
> Prevod je izašao sa `"Ringe ringe raja" "` u jednom cue-u i `Ringe raja sa ""` u
> sledećem. Model je vratio uredan tekst. Tokenizer odvaja pravi navodnik od
> reči i ne zna otvara li ili zatvara citat, pa je rez smeo da padne između
> navodnika i reči. Popravka: **pre raspoređivanja** svaki pravi navodnik
> postaje usmereni oblik ciljnog jezika, a oni se lepe za reč i ne mogu se
> razdvojiti.

Šta ovaj režim ne može — reci korisniku, ne pogađaj

- Nema slušanja ni bojenja po sigurnosti (nema zvuka ni verovatnoća po rečima). Crvene su samo rečenice čiji cue probija profil i gori je nego u originalu.
- **Kurziv preko dela rečenice se gubi.** Posle prevoda se ne može pouzdano vratiti na isto mesto, pa cue **prijavi** umesto da pogađaš. Cue koji je ceo u kurzivu ostaje u kurzivu.
- **Nedosledna interpunkcija u ulazu pravi greške.** Cue `Ja sam Marko` bez tačke, praćen cue-om `Imam 12 godina`, daje rečenicu u kojoj model čita `Imam` kao prezime: `Je suis Marko Imam`. Rešenje je u ulazu, ne u alatu — ali prijavi sumnju.

FAZA 7 — objašnjenja u interfejsu

Alat koji si napravio biće jasan tebi, jer si svaku odluku sam doneo. Nekome ko ga prvi put otvori nijedna od njih nema vidljiv razlog.

Dodaj objašnjenja u **dva sloja**, nikad kao zid teksta:

- **sloj 1** — jedan red ispod oznake polja, uvek vidljiv, kaže *šta da izaberem*
- **sloj 2** — `zašto ovo`, razvija se na klik, zatvoreno po default-u, sadrži razlog i izmerene brojeve

Jedna komponenta za oba sloja, bez JavaScripta (`<details>` i `<summary>` su dovoljni). Duže celine — upotreba editora, garancija tajminga u fazi 6, ograničenja tog režima — stoje kao trake koje se razvijaju iznad sadržaja na koji se odnose. Dodaj i zasebnu stranicu *Kako ovo radi* sa oba toka u koracima i tabelom čestih problema.

Kad ovo radiš, **izbaci stare jednoredne napomene** razbacane po ekranima — nova objašnjenja ih pokrivaju potpunije i na jednom mestu. Ostavi samo oznake koje se odnose na konkretan red.

> **ZAMKA 19 — tekst objašnjenja pisan prema dokumentaciji ne slaže se sa kodom.**
> Od dvadeset pripremljenih tekstova, devet je odstupalo od stvarnog stanja: dugme
> koje je opisano a nikad napravljeno, pogrešno najveće trajanje profila, boja
> oznake opisana kao narandžasta iako je žuta, polja smeštena na pogrešan ekran,
> tvrdnja o potvrdi koja postoji samo u komandnoj liniji. **Svaki broj i svaku
> tvrdnju u objašnjenju proveri u izvoru pre ugradnje**, i gradi tabele iz stvarnih
> datoteka (profili, podešavanja) umesto da ih prepisuješ — tako ne mogu zastariti.
> Broj koji ne možeš proveriti iz koda nemoj prepisati: izmeri ga ili ga izostavi.

FAZA 8 — interfejs iz temelja

Prvi interfejs će biti tabela polja bez hijerarhije i to je u redu dok ga koristiš

sam. Kad ga prvi put pogleda neko drugi, prepravka traje dugo ako se radi mesto po mesto. **Postavi četiri pravila odmah i napiši test za svako:**

1. **Objašnjenje je ikonica i prozorčić, nikad tekst na stranici.** Nikakve trake koje se razvijaju u toku sadržaja — one guraju sve naniže i gube ti mesto. Prozorčić lebdi, zatvara se klikom van, ponovnim klikom i `Esc`, najviše jedan otvoren. Test pada ako negde ostane traka sa objašnjenjem.
2. **Ispod jedne trake najviše jedan red teksta.** Kad svako polje nosi svoje objašnjenje, ispod trake od četiri polja stoje četiri pasusa i ništa se ne čita.
3. **Radnja ne pomera pogled.** Isti skrol, isto fokusirano polje, iste otvorene trake posle svake radnje.
4. **Dugme kaže šta radi**, nikad „OK". Potvrde kroz sopstveni prozor; nativni nosi adresu servera u naslovu i dugmad na engleskom.

> **ZAMKA 25 — pravilo se vraća dok se prijavljuje kao mesto.** Ista stavka — objašnjenje kao traka umesto ikonice — popravljana je pet puta zaredom, jer je svaki put pokazana na jednom ekranu. Prestala je tek kad je formulisana kao pravilo sa obavezom da se prođe kroz **svaki** šablon i sa testom koji pada ako se vrati. Isti test je odmah uhvatio dva mesta koja niko nije prijavio.

Prelom se mora videti u editoru

Ovo je najskuplje nesporazumljenje u celom projektu i rešava se prikazom, ne promenom modela.

Editor uređuje **rečenice**, a profil, pismo i veličina slova menjaju **titl**. Tekst u editoru ostaje isti, pa izgleda da izbor ne radi — prijavljeno tri puta kao kvar, a svaki put je funkcija radila ispravno.

Ispod svake rečenice prikaži cue-ove koji su iz nje nastali, tačno kako stoje u datoteci: prelom redova, pismo, veličina slova, interpunkcija, vreme svakog cue-a. Monospace, sitnije, prigušeno. Cue koji probija profil ili je prekratak obeleži bojom i tu. Prekidač za isključivanje, jer na dugom prepisu udvostručuje visinu liste.

Nijedna izmena ne čeka na dugme

Prelamanje je deterministično, ne poziva model i traje deo sekunde (na satu prepisa od 1683 rečenice oko 0,9 s). Nema razloga da ga pokreće dugme:

- promena bilo kog izbora prelama odmah, uz odlaganje od 300 ms da dve brze promene daju jedno prelamanje;
- izlazak iz polja sa izmenjenim tekstom snima i prelama;
- osvežava se **samo deo sa prelomom**, ne cela stranica — inače se vidi kako se vraća stari pa posle sekunde dolazi novi;
- stanje snimanja nosi ikonica, ne rečenica na stranici.

Kad to uradiš, potvrda „titl ponovo prelomljen" postaje suvišna — promena se vidi u samom prelomu. Zadrži je samo za grešku.

Testovi

Ciljaj na blizu hiljadu testova i **najmanje 85% pokrivenosti naredbi**, sa težištem na modulima gde je greška tiha: prelamanje, transliteracija, segmentacija, ekavizacija, spajanje elizija, validacija odgovora modela, očuvanje tajminga u fazi 6.

> **ZAMKA 26 — broj testova nije pokrivenost, i razlika ume da bude ogromna.**
> Pri 1140 testova pokrivenost je prvi put izmerena: glavna faza pajplajna — funkcija koja se najviše menjala — bila je na **1%**. Nijedan test nije prolazio kroz nju, jer traži model i karticu, pa je svaka izmena u njoj mogla da prođe nezapaženo do prvog stvarnog posla.

> **Meri pokrivenost od prve faze**, ne na kraju, i prijavljuj je po modulu.

Za fazu koju nijedan test ne dodiruje, recept je isti i ne traži menjanje koda: napiši test koji **podmeće samo spoljne stvari** — pripremu zvuka, merenje govora, prepoznavanje i jezički model — a sve ostalo pušta kroz pravi kod i proverava **ishode**, ne pozive: nastale datoteke, broj reči i rečenica, oznake, faze i redove u dnevniku. Pripremi više ulaza, da svaki bira drugu granu: jedan koji pali ekavizaciju i kapiju interpunkcije, jedan sa razdvojenim elizijama i gustom interpunkcijom gde kapija ne okida, i jedan sa repom reči nultog trajanja. Test koji samo gleda da je funkcija pozvana prolazi i kad je rezultat pogrešan — takav ne piši.

Ne deli dugačku funkciju da bi je testirao. Dužina nije rizik; nepokrivenost jeste. Deljenje bi premestilo isti sadržaj u druge fajlove i tražilo objekat stanja kroz korake, a pokrivenost bi ostala ista.

Nekoliko testova su **namenske brane** koje pamte skupo plaćene nalaze. Najvažniji proverava da `hallucination_silence_threshold` nije vraćen u podrazumevane parametre, sa objašnjenjem u samom testu da je taj parametar gutao rep zapisa i koštao 28% pokrivenosti.

> **ZAMKA 24 — zaštita nabrajanjem propušta ono što još nije napisano.**
> Test koji je samo podigao server pokrenuo je migraciju nad **stvarnim** podacima,
> pre nego što je napravljena rezervna kopija. Zaštita koja je iz toga nastala
> nabrajala je ono što je stradalo — direktorijum poslova i podešavanja — pa se tri
> kruga kasnije isti kvar ponovio na glosaru.
> **Okreni pravilo naopako:** svaki test dobija privremen koren projekta, a pisanje
> bilo gde izvan njega je greška, ne izuzetak. Jedan `conftest.py` koji to podmeće
> svakom testu bez izuzetka, i provera koja pada ako je išta u stvarnom
> repozitorijumu dirnuto tokom celog skupa. Tada ne moraš da pamtiš koji je fajl
> osetljiv. Svaki nov kod koji radi pri pokretanju zamisli kao nešto što će test
> pokrenuti.

Kuriozitet koji je pojeo pola sata: generator testova je upisao **stvarni upravljački bajt** umesto oznake granice reči u obrazac za pretragu, pa su tri testa padala bez vidljivog razloga. Nađeno prikazom nevidljivih znakova.

Kako da mi javljaš stanje

- Posle svake faze: šta je izmereno, konkretni brojevi, šta je ostalo otvoreno.
- Kada nađeš da moja pretpostavka ne stoji: **reci pre nego što uradiš**, sa merenjem koje to pokazuje.
- Komanda za zaustavljanje procesa mora biti **filtrirana na ovaj projekat** — komanda koja gasi sve Python procese mi je jednom prekinula drugi projekat:

```powershell
Get-CimInstance Win32_Process -Filter "Name like '%python%'" |
  Where-Object { $_.CommandLine -like '*subtitis*' } |
  ForEach-Object { Stop-Process -Id $_.ProcessId -Force }
```

Počni od faze 1.